

딥러닝 파이토치 교과서 5장 - Part 2 (5.3~)

📅 날짜	@2026년 3월 31일
🏆 발표팀	4팀
⚙️ 상태	시작 전
🏷️ 태그	4주차

전이학습: 이미지넷처럼 아주 큰 데이터셋을 써서 훈련된 모델의 가중치를 가져와 우리가 해결하려는 과제에 맞게 보정해서 사용하는 것을 의미함. 이때 아주 큰 데이터셋을 사용하여 훈련된 모델을 사전 훈련된 모델이라고 함.

이를 위한 방법으로는 특성 추출과 미세 조정 기법이 있음


1. 특성 추출 기법

ImageNet 데이터셋으로 사전 훈련된 모델을 가져온 후 마지막에 완전연결층 부분만 새로 만들.

즉, 마지막 완전연결층 부분만 새로 만들고, 나머지는 학습되지 않도록 하는 것임.

사전훈련된 모델(네트워크)의 합성곱층(가중치 고정)에 새로운 데이터를 통과시키고, 그 출력을 데이터 분류기에서 훈련시키는 것을 말함. 그러니까 합성곱층 재사용임

▼ 그림 5-30 특성 추출 기법



사용 가능한 이미지 분류 모델

- Xception, Inception V3, ResNet50, VGG16, VGG19, MobileNet 등

데이터 전처리 (transforms)

Resize([256, 256]) : 합성곱층 통과를 위한 이미지 크기 조정 (전처리)

RandomResizedCrop(224) : 랜덤한 비율로 자른 후 크기 조정 (데이터 확장 용도)

RandomHorizontalFlip() : 이미지를 랜덤하게 수평으로 뒤집음

ToTensor() : 이미지를 [0,1] 범위의 텐서로 변환

Resize와 RandomResizedCrop의 차이:

- Resize는 크기 맞추기(전처리)
- RandomResizedCrop은 데이터 다양성 확보(증강)

DataLoader 주요 파라미터

batch_size : 한 번에 불러올 데이터 개수

num_workers : 데이터를 불러올 하위 프로세스 수 (너무 많으면 오류 발생)

shuffle : True이면 데이터를 무작위로 섞어서 불러옴

RandomResizedCrop 파라미터

`transforms.RandomResizedCrop(size=(200, 200), scale=(0.1, 1), ratio=(0.5, 2))`

size : 출력할 크기 (200x200)

scale : 면적 비율 0.1~1(10~100%) 범위에서 무작위로 자름

ratio : 너비와 높이 비율을 0.5~2 범위에서 무작위 조절

학습 데이터 시각화

데이터로더에서 이미지를 꺼낼 때 `iter()` + `next()`를 사용한다.

- `iter()`: 반복자를 꺼내 반환
- `next()`: 반복자가 다음에 출력해야 할 요소를 반환

이미지 시각화 시 `np.transpose(샘플, (1,2,0))`으로 차원 순서를 (C,H,W) → (H,W,C)로 바꿔야 한다.

사전 훈련된 ResNet18

ResNet18: 18개의 계층으로 구성된 합성곱 신경망. ImageNet 100만 개 이상의 이미지로 학습된 사전 훈련 모델이다.

파이토치에서 제공하는 주요 사전 훈련 모델:

`resnet18`, `alexnet`, `vgg16`, `densenet161`, `inception_v3`, `googlenet`, `mobilenet_v2` 등

가중치 고정 (`requires_grad`)

`param.requires_grad = False`

→ 역전파 중 파라미터 변화 계산 불필요, 가중치 고정

특성 추출 시 합성곱층은 고정하고, 완전연결층만 학습시킨다.

완전연결층 교체

`resnet18.fc = nn.Linear(512, 2) # 2: 클래스 수 (cat, dog)`

모델 학습 과정 요약

1. `optimizer.zero_grad()` — 기울기 초기화
2. `outputs = model(inputs)` — 순전파
3. `loss = criterion(outputs)` — 손실 계산
4. `loss.backward()` — 역전파
5. `optimizer.step()` — 파라미터 업데이트

모델 평가

- `torch.no_grad()`: autograd 비활성화 (추론 시 메모리 절약)

- `torch.max(outputs.data, 1)`: 텐서에서 최댓값의 인덱스 반환
- `preds.eq(labels).sum()`: 예측과 정답이 일치하는 개수 계산

결과

- 훈련 데이터 최고 정확도: 약 93%
- 테스트 데이터 최고 정확도: 약 94.9%
- 에포크가 진행될수록 정확도 상승, 오차 감소

5.3.2 미세 조정 기법 (Fine-tuning)

특성 추출에서 더 나아가, 사전 훈련된 모델의 합성곱층과 데이터 분류기 모두 재학습시키는 방식이다.

특성이 잘못 추출된 경우(예: ImageNet과 전자상거래 이미지의 특징이 다른 경우), 새로운 데이터로 네트워크 가중치를 업데이트하여 특성을 다시 추출할 수 있다.

전략 (데이터셋 크기 × 사전 훈련 모델 유사성)

데이터셋 크다 + 유사성 작다 → 모델 전체 재학습

데이터셋 크다 + 유사성 크다 → 합성곱층 뒷부분 + 데이터 분류기 학습

데이터셋 작다 + 유사성 작다 → 합성곱층 일부 + 데이터 분류기 학습

데이터셋 작다 + 유사성 크다 → 데이터 분류기(완전연결층)만 학습

미세 조정 시 파라미터에 큰 변화를 주면 과적합이 발생할 수 있으므로, 정교하고 미세한 파라미터 업데이트가 필요하다. GPU 사용 권장.

5.4 설명 가능한 CNN (Explainable CNN / XAI)

개념

CNN은 블랙박스처럼 내부 동작을 설명하기 어렵다. 설명 가능한 CNN은 처리 결과를 사람이 이해할 수 있는 방식으로 제시하는 기술이다.

CNN 시각화 방법:

- 필터 시각화
- 특성 맵 시각화 (이 장에서 다룸)

5.4.1 특성 맵 시각화 (Feature Map Visualization)

특성 맵(활성화 맵)은 필터를 입력에 적용한 결과이다. 특성 맵 시각화를 통해 CNN이 입력 이미지에서 특성을 어떻게 추출하는지 이해할 수 있다.

XAI 모델 구조

- 합성곱층 13개 + 완전연결층 2개
- 활성화 함수: ReLU (모든 계층에 사용)

핵심 개념

inplace=True

기존 데이터를 연산 결과로 대체한다. 메모리를 절약하는 효과가 있다.

log_softmax

소프트맥스 결과에 log를 취한 연산. 소프트맥스는 기울기 소멸 문제에 취약하기 때문에 log_softmax를 사용한다.

register_forward_hook

파이토치에서 각 계층의 활성화 함수 및 기울기를 확인할 수 있는 기능. 순전파 중 각 네트워크 모듈의 입력 및 출력을 가져온다.

cv2.resize 보간법 (interpolation)

이미지 크기를 변경할 때 존재하지 않는 픽셀 값을 추정하는 방법.

- INTER_LINEAR: 선형 보간법 (가장 일반적으로 사용)

unsqueeze(dim)

텐서에 차원을 추가한다.

- `unsqueeze(0): [C,H,W] → [1,C,H,W]`

tensor 복사 비교

`tensor.clone()` : 메모리 새로 할당 / 계산 그래프에 상주

`tensor.detach()` : 메모리 공유 / 계산 그래프에 상주하지 않음

`tensor.clone().detach()` : 메모리 새로 할당 / 계산 그래프에 상주하지 않음

clip(min, max)

입력 값이 주어진 범위를 벗어날 때 특정 범위로 제한한다.

`image.clip(0, 1) → 0~1 사이의 값으로 제한`

특성 맵 시각화 결과 해석

0번째 계층 (입력층에 가까움) : 입력 이미지의 형태가 많이 유지됨

20번째 계층 (중간) : 원본 이미지 형태를 찾아볼 수 없게 됨

40번째 계층 (출력층에 가까움) : 이미지 형태는 사라지고 이미지 특징들만 전달됨

→ 계층이 깊어질수록 원본 이미지 형태는 사라지고 추상적인 특징만 남는다.

5.5 그래프 합성곱 네트워크 (GCN)

5.5.1 그래프란?

방향성이 있거나(directed) 없는(undirected) 에지로 연결된 노드(nodes)의 집합.

- 노드(node, vertex): 원소를 의미
- 에지(edge): 두 노드를 연결한 선 (결합 방법을 의미)

5.5.2 그래프 신경망 (GNN)

그래프 구조에서 사용하는 신경망. 그래프 데이터 표현은 두 단계로 이루어진다.

1. 인접 행렬 (Adjacency Matrix): 노드 n 을 $n \times n$ 행렬로 표현. 컴퓨터가 이해하기 쉽게 그래프를 표현하는 과정.
2. 특성 행렬 (Feature Matrix): 인접 행렬만으로는 특성 파악이 어려우므로 단위 행렬을 적용. 각 노드가 가지는 특성 값을 행렬로 표현.

5.5.3 그래프 합성곱 네트워크 (GCN)

이미지에 대한 합성곱을 그래프 데이터로 확장한 알고리즘.

리드아웃(readout): 특성 값을 하나의 벡터로 변환하는 함수. 전체 노드의 특성 벡터에 대해 평균을 구하고 그래프 특성을 표현하는 하나의 벡터를 생성한다.

GCN에서 가장 중요한 부분은 그래프 합성곱층: 그래프 형태의 데이터를 행렬 형태로 변환하여 학습 알고리즘을 적용할 수 있게 한다.

GCN 활용 분야

- SNS에서 관계 네트워크
- 학술 연구에서 인용 네트워크
- 3D Mesh

핵심 요약

특성 추출	: 합성곱층 고정, 분류기만 학습	/ 데이터 적고 사전 모델과 유사할 때
미세 조정	: 일부/전체 계층 재학습	/ 데이터 많거나 사전 모델과 다를 때
XAI(특성 맵)	: 각 계층의 특성 맵 시각화	/ CNN 내부 동작 이해/신뢰성 확보
GCN	: 그래프 데이터에 합성곱 적용	/ 관계 네트워크, 분자 구조 분석 등