딥러닝 시작

4.1 인공신경망의 한계와 딥러닝 출현

- 퍼셉트론 : 신호를 입력으로 받아 정보 전달
- AND 게이트 : 모든 입력이 1일 때 작동

표 4-1 AND 게이트

x_1	x_2	y
0	0	0
1	0	0
0	1	0
1	1	1

- OR 게이트 : 입력에서 둘 중 하나만 1이거나 둘 다 1일 때 작동

표 4-2 OR 게이트

x_1	x_2	y
0	0	0
1	0	1
0	1	1
1	1	1

- XOR 게이트 : 입력 2개 중 1개만 1일 때 작동하는 논리 연산

4.2 딥러닝 구조

딥러닝 → 여러 층을 가진 인공신경망을 사용하여 학습을 수행하는 것

4.2.1 딥러닝 용어

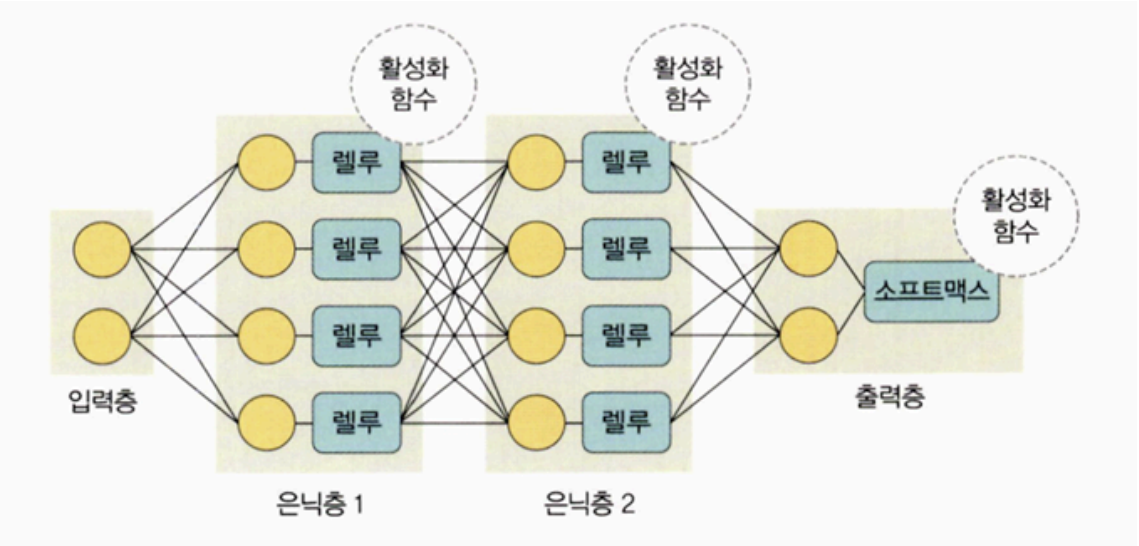

- 가중치 : 입력값이 연산 결과에 미치는 영향력을 조절하는 요소
- 가중합 : 노드에서 들어오는 신호에 가중치를 곱한 값들을 모두 더한 합계

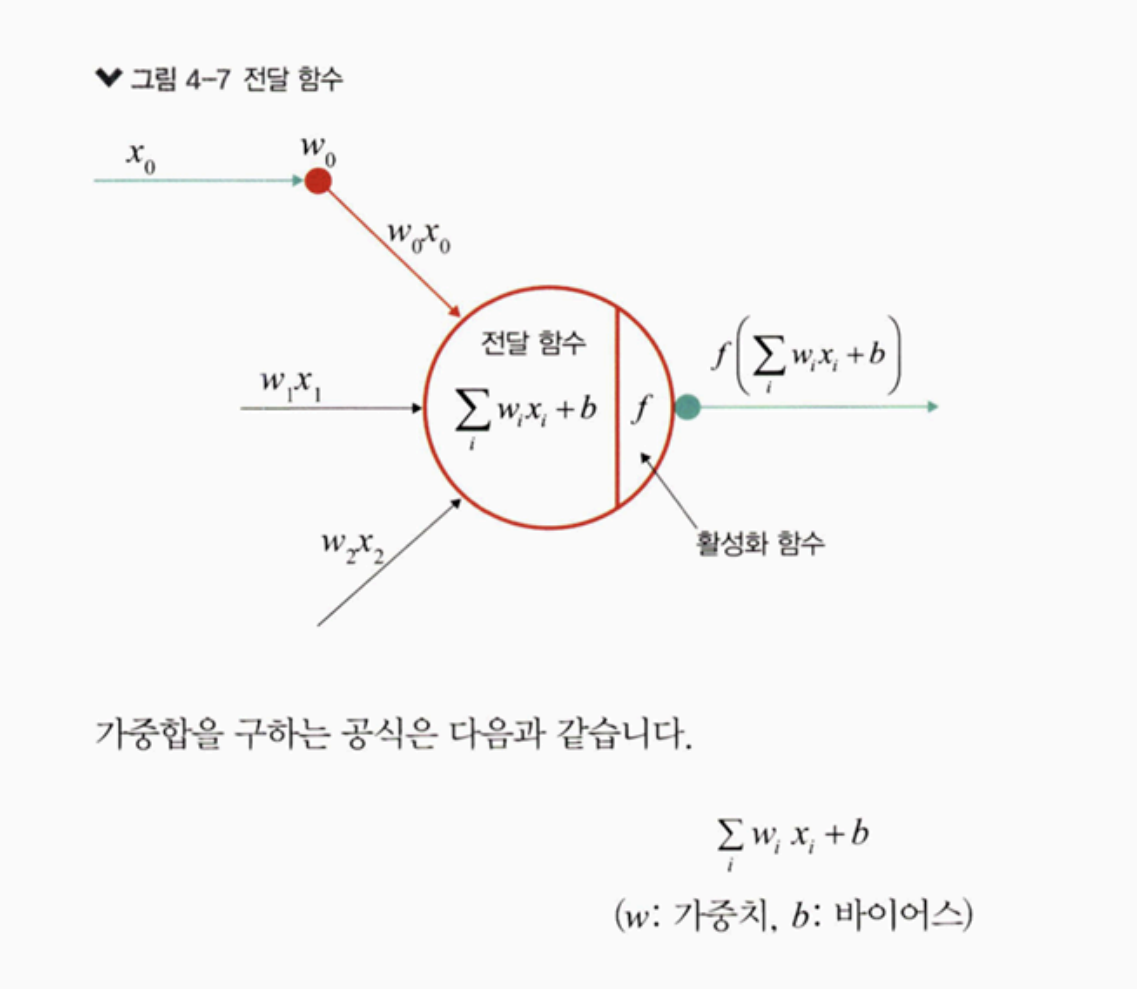

- 활성화 함수 : 전달함수에서 전달받은 값을 출력할 때 일정 기준에 따라 출력 값을 변화시키는 비선형 함수
  - 시그모이드, hyperbolic tangent, RELU 등

1. 시그모이드

$$f(x) = \frac{1}{1+e^{-x}}$$

- 선형함수의 결과를 0~1 사이에서 비선형 형태로 변형하며, 분류 문제를 확률적으로 표현할 때 사용
- 기울기 소멸 문제 존재

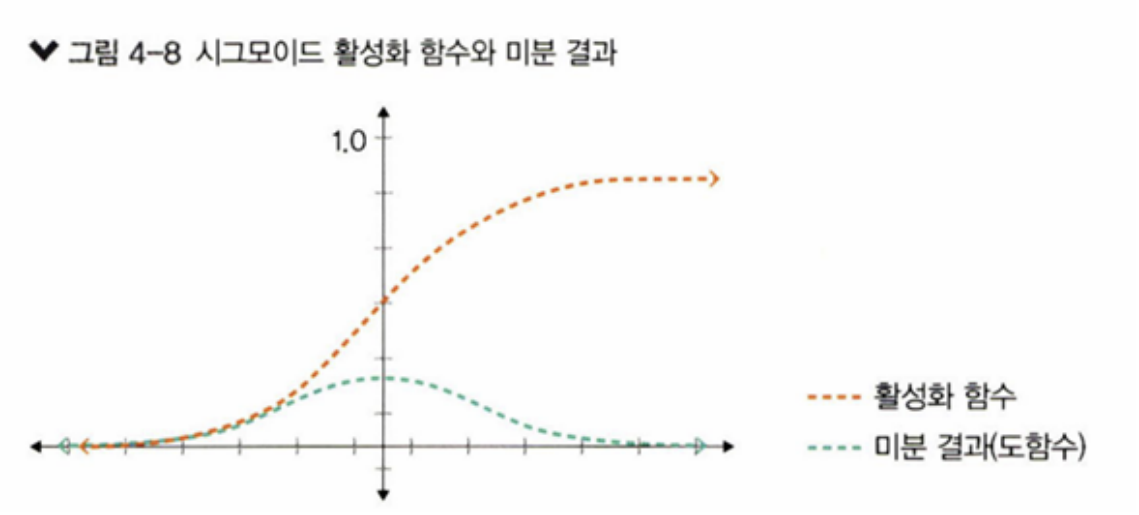

2. 하이퍼볼릭 탄젠트 함수

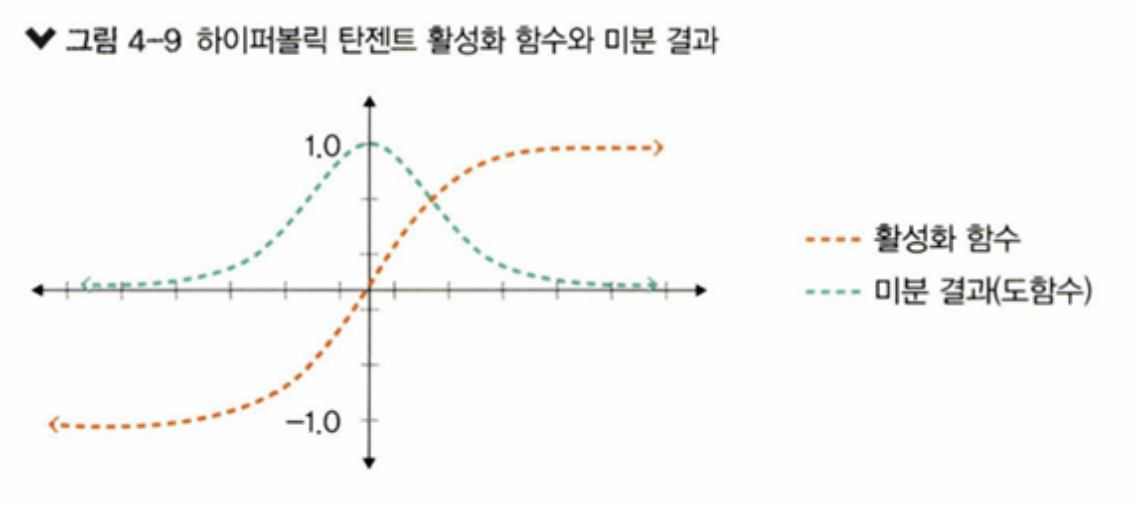

- 선형 함수의 결과를 -1~1 사이에서 비선형 상태로 변형
  - 기울기 소멸 문제 존재

3. 렐루 함수

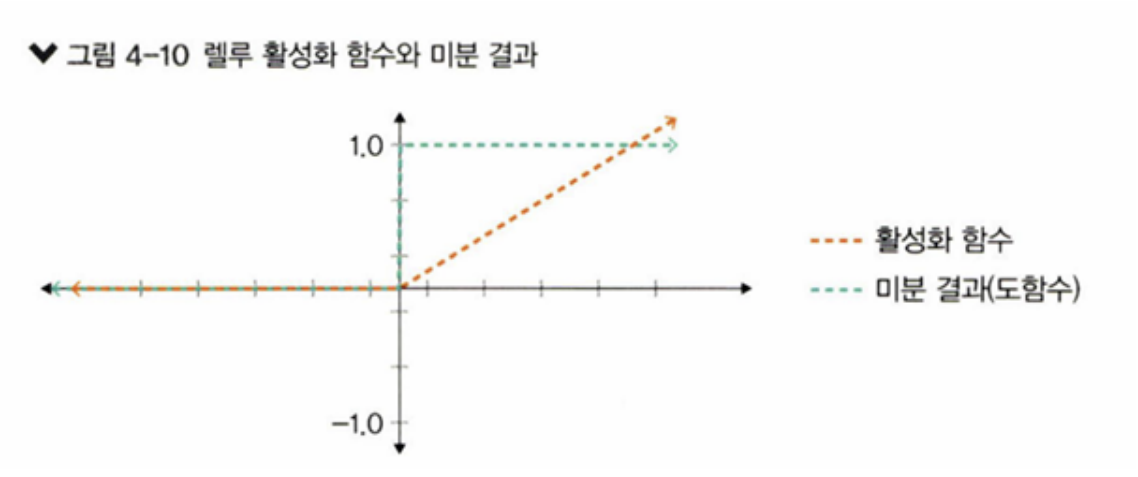

- 입력이 음수일 때는 0 출력, 양수일 때는 x 출력
  - 경사하강법에 영향 X : 학습 속도가 빠르고, 기울기 소멸 문제 X
- 은닉층에서 사용
  - Leaky RELU : 음수값을 입력받으면 항상 0 출력하는 문제 해결하기 위해

4. 리키 렐루 함수

- 입력값이 음수이면 0이 아닌 아주 작은 값 반환

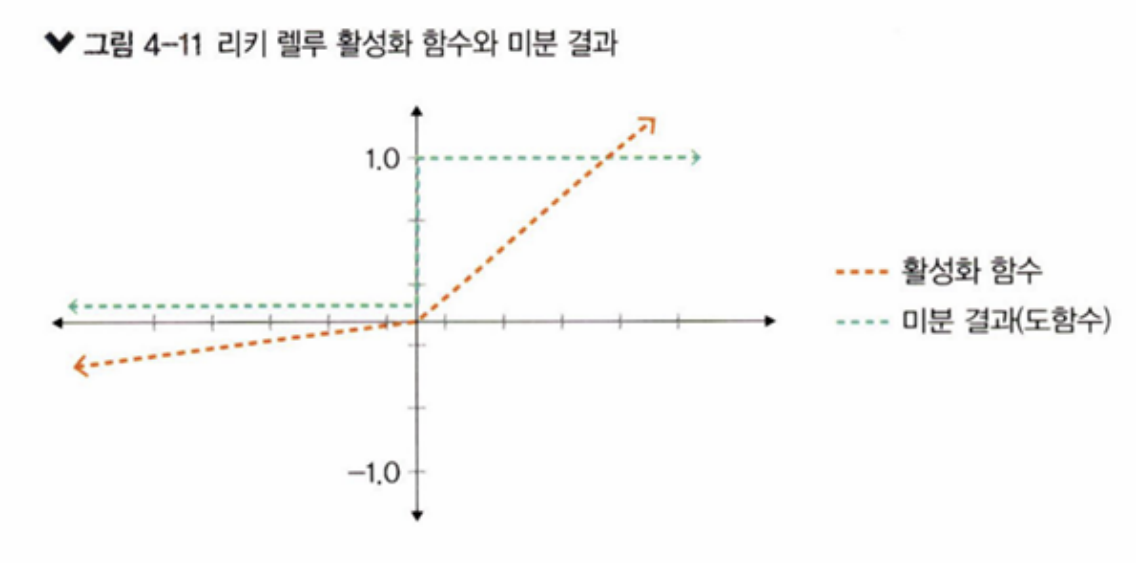

5. 소프트맥수 함수

- 입력값을 0~1 사이에 출력되도록 정규화해 출력값들의 총합이 항상 1이 되도록

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^{n} \exp(a_i)}$$

- 손실함수 : 미분의 기울기를 이용해 오차를 비교하고 최소화할 때, 오차를 구하는 방법

→ 얻은 데이터의 추정치가 실제 데이터와 얼마나 차이가 나는지 평가하는 지표

- MSE : 평균제곱오차

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

$$\left(\begin{array}{l} \hat{y}_i\text{: 신경망의 출력(신경망이 추정한 값)} \\ y_i\text{: 정답 레이블} \\ i\text{: 데이터의 차원 개수} \end{array}\right)$$

- 크로스 엔트로피 오차 : 분류 문제에서 원핫인코딩 했을 때 사용할 수 있는 오차 계산법
  - 경사하강법 과정에서 학습이 지역 최소점에서 멈출 수 있음

$$CrossEntropy = -\sum_{i=1}^{n} y_i \log \hat{y}_i$$

$$\left(\begin{array}{l} \hat{y}_i\text{: 신경망의 출력(신경망이 추정한 값)} \\ y_i\text{: 정답 레이블} \\ i\text{: 데이터의 차원 개수} \end{array}\right)$$

4.2.2 딥러닝 학습

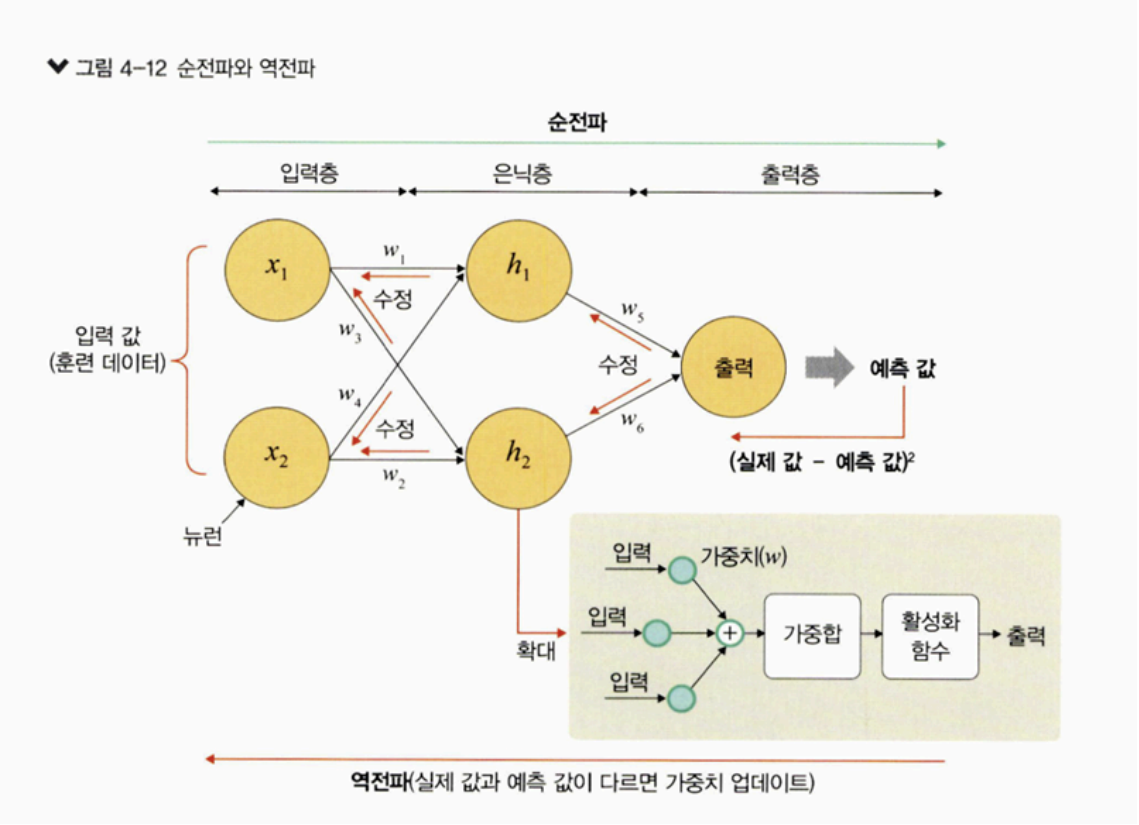

1. 순전파 : 훈련 데이터가 모든 층을 통과해서 모든 뉴런이 계산
2. 역전파 : 네트워크의 예측값과 실제값의 차이를 이용해 가중치 조정

4.2.3 딥러닝의 문제점과 해결방안

1. 과적합 문제 발생 : 훈련 데이터를 과하게 학습해 실제 데이터는 잘 맞추지 못해 오차 증가

→ 해결방안 : 드롭아웃

- 학습 과정 중 임의로 일부 노드들을 학습에서 제외

2. 기울기 소멸 문제 발생 : 출력층에서 은닉층으로 전달되는 오차가 크게 줄어들어 학습이 되지 않는 현상

→ 해결방안 : RELU 활성화 함수

3. 성능이 나빠지는 문제 : 경사하강법에서 손실함수의 비용이 최소가 되는 지점을 찾을 때까지 기울기가 계속 이동하는 과정에서 발생

→ 해결방안 : 확률적 경사 하강법, 미니배치 경사 하강법

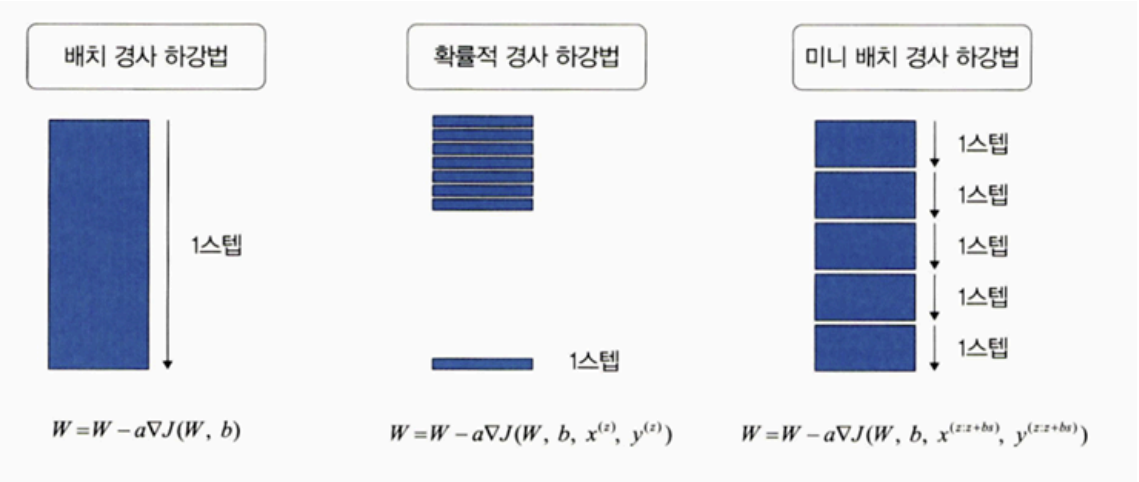

- 배치 경사 하강법 : 전체 데이터셋에 대한 오류를 구한 후 기울기를 한번만 계산해 모델의 파라미터를 업데이트 → 전체 훈련 데이터셋에 대해 가중치를 편미분

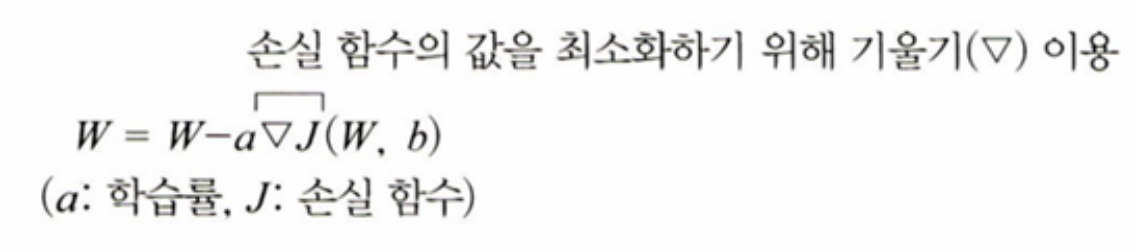

- 확률적 경사 하강법 : 임의로 선택한 데이터에 대해 기울기를 계산 → 빠른 계산 가능, 속도 빠름

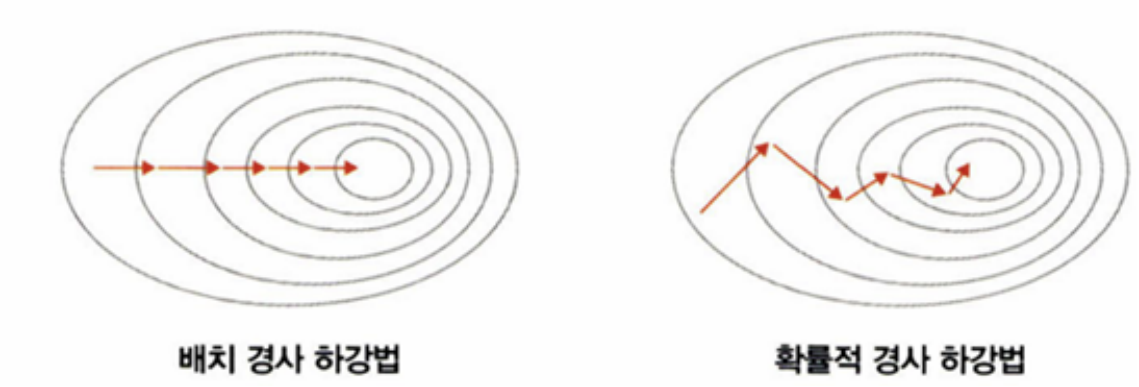

- 미니 배치 경사 하강법 : 전체 데이터셋을 미니배치 여러 개로 나누고, 미니 배치 한 개마다 기울기를 구한 후 그것의 평균 기울기를 이용해 모델을 업데이트해 학습

  → 빠른 계산 가능, 확률적 경사하강법에 비해 안정적

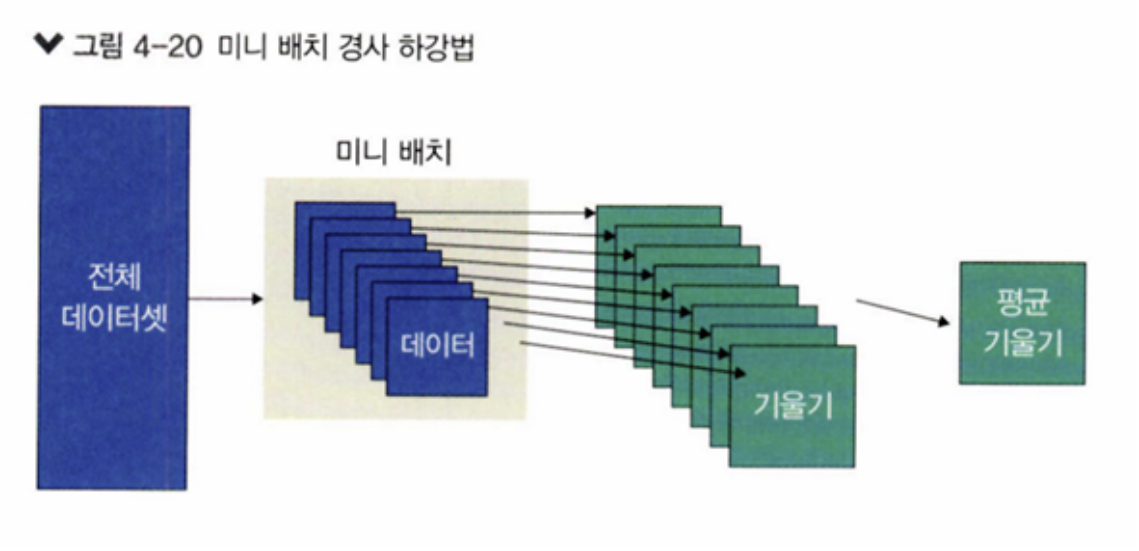

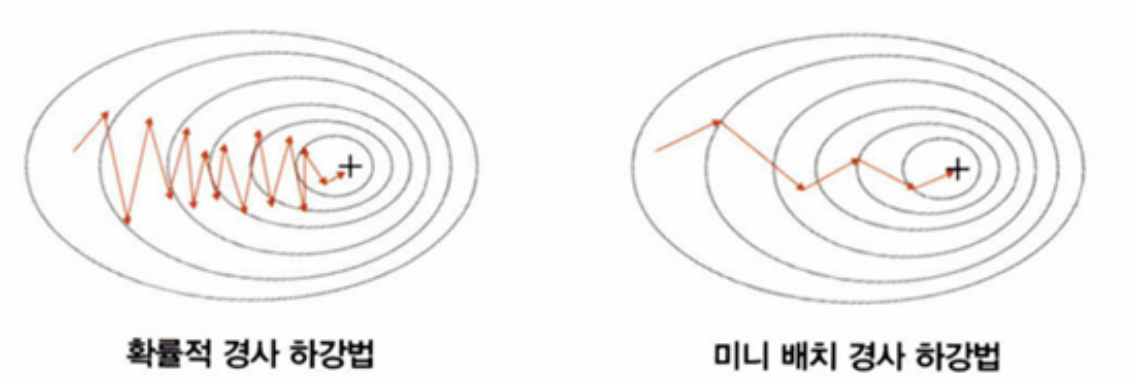

4.2.4 딥러닝의 장점

1. 특성 추출 : 머신러닝과 달리, 딥러닝은 데이터별로 특징을 추출하는 과정 자체를 알고리즘에 통합
2. 빅데이터 효율적 활용 : 딥러닝 학습을 이용한 특성 추출은 데이터 사례가 많을수록 성능 향상

4.3 딥러닝 알고리즘

→ 심층 신경망 사용 (CNN, RNN, 제한된 볼츠만 머신, 심층 신뢰 신경망)

4.3.1 심층 신경망(DNN)
: 입력층과 출력층 사이에 다수의 은닉층을 포함하는 인공 신경망 → 별도 트릭 없이 비선형 분류 가능

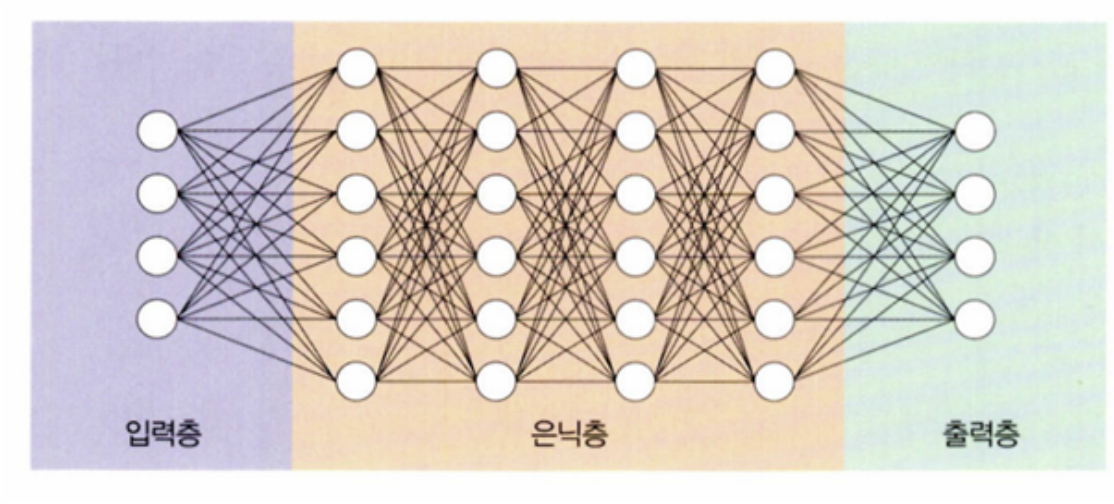

4.3.2 합성곱 신경망

: 합성곱층(convolutional layer)과 풀링층(pooling layer)을 포함하는 이미지 처리 성능이 좋은 인공 신경망 알고리즘

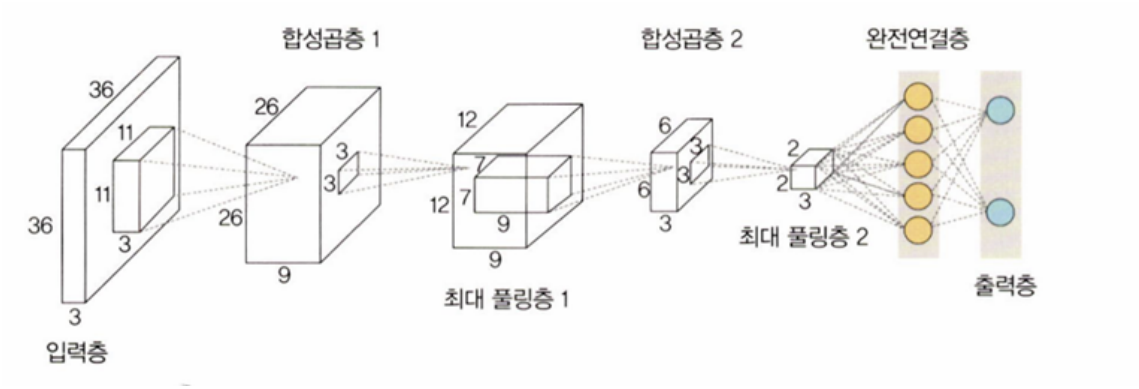

ex) LeNet-5, AlexNet, VGG, GoogLeNet, ResNet

→ 기존 신경망과 다른 점

- 각 층의 입출력 형상을 유지
- 이미지의 공간 정보를 유지하며, 인접 이미지와 차이가 있는 특징을 효과적으로 인식
- 복수 필터로 이미지의 특징을 추출하고 학습
- 추출한 이미지의 특징을 모으고 강화하는 풀링층 존재
- 필터를 공유 파라미터로 사용하기 때문에 학습 파라미터가 상대적으로 적음

4.3.3 순환 신경망

: 시계열 데이터 등 시간 흐름에 따라 변화하는 데이터를 학습하기 위한 인공 신경망

- 순환(recurrent) : 자기 자신을 참조함 → 현재 결과가 이전 결과와 연관있음

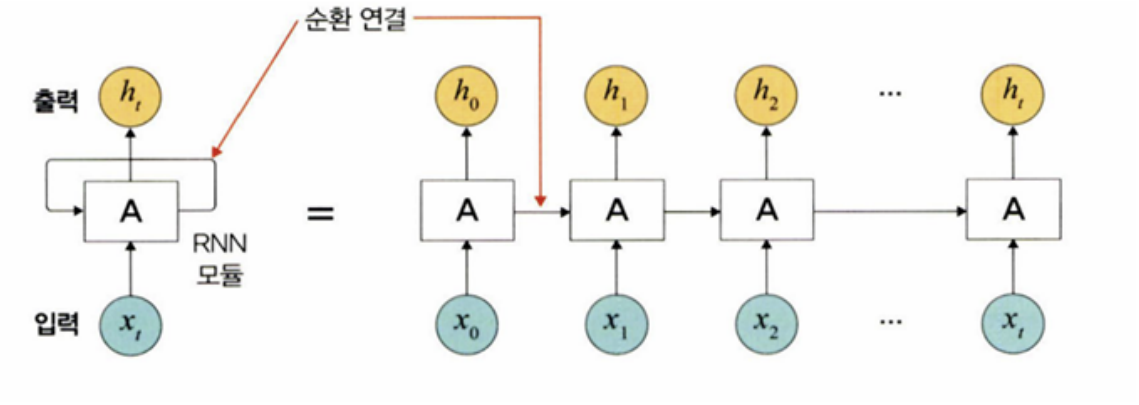

- 시간성(temporal property)을 가진 데이터가 많음
- 시간성 정보를 이용해 데이터 특징을 잘 다룸
- 시간에 따라 내용이 변하므로 데이터가 동적, 길이는 가변적
- 기울기 소멸 문제 → 학습이 잘 되지 않는 문제 ↔ LSTM 사용(메모리 개념 도입)
- 자연어 처리 : 언어 모델링, 텍스트 생성, 번역, 음성 인식, 이미지 캡션 생성

4.3.4 제한된 볼츠만 머신

볼츠만 머신 : 가시층(visible layer)과 은닉층(hidden larger)으로 구성된 모델 → 제한된 볼츠만 머신 : 가시층은 은닉층과만 연결됨

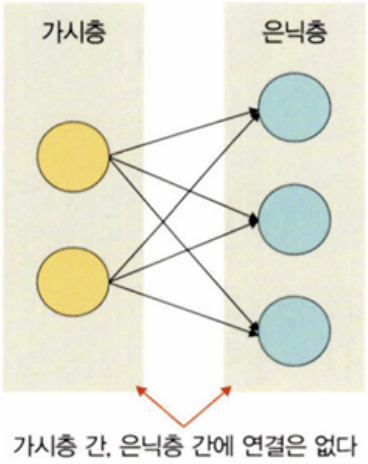

- 차원 감소, 분류, 선형회귀분석, 협업 필터링, 특성 값 학습, 주제 모델링에 사용
- 기울기 소멸 문제를 해결하기 위해 사전학습 용도로 활용가능
- 심층 신뢰신경망(DBN) 요소로 활용

4.3.5 심층 신뢰 신경망

: 제한된 볼츠만 머신을 블록처럼 여러 층으로 쌓은 형태로 연결된 신경망

- 레이블 없는 데이터에 대해 비지도 학습 가능
- 학습 절차
    - 가시층과 은닉층1에 제한된 볼츠만 머신을 사전 훈련

- 첫번째 층 입력데이터와 파라미터를 고정해 두번째 층 제한된 볼츠만 머신을 사전훈련
- 원하는 층 개수만큼 제한된 볼츠만 머신을 쌓아올려 전체 DBN 완성

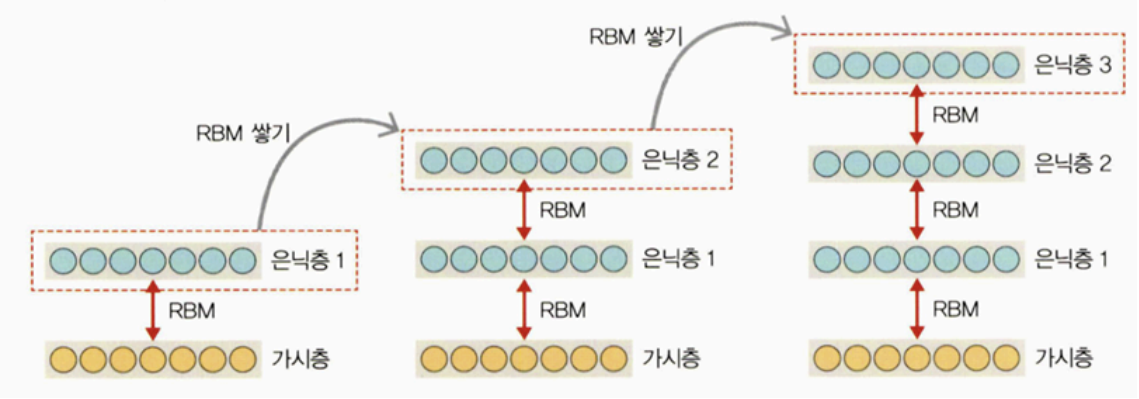

- 순차적으로 심층 신뢰 신경망 학습 → 계층적 구조 생성
- 비지도 학습
- 위로 올라갈수록 추상적 특성을 추출
- 학습된 가중치를 다층 퍼셉트론의 가중치 초깃값으로 사용

4.4 우리는 무엇을 배워야할까

선형 회귀 → 머신러닝

복잡한 비선형 데이터 → 딥러닝

→ 목적에 따라 머신러닝/딥러닝을 활용할 수 있는 능력 필요