Week2_예습과제

통계 수정 삭제

카사바 · 방금 전

0

4장 딥러닝 시작

4.1 인공 신경망의 한계와 딥러닝 출현

퍼셉트론: 오늘날 신경망(딥러닝)의 기원이 되는 알고리즘

AND 게이트 : 모든 입력이 1일 때 작동한다.

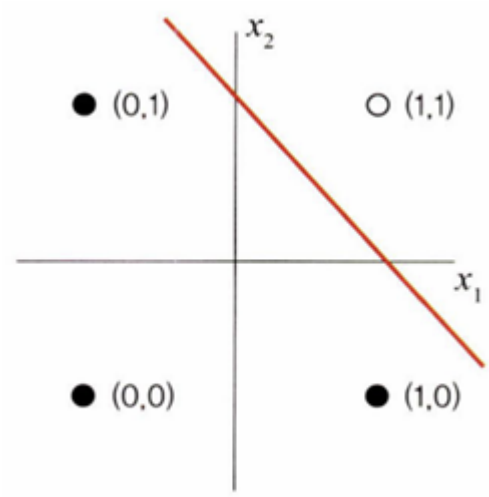

OR 게이트 : 입력에서 둘 중 하나만 1이어도 작동한다.

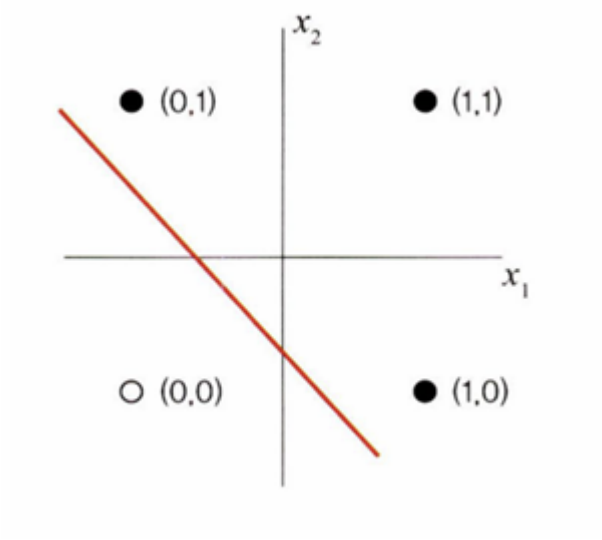

XOR 게이트 : 입력 두 개 중 한 개만 1일 때 작동한다. 데이터가 비선형적으로 분리되기 때문에 제대로 된 분류가 어렵다. 즉, 단층 퍼셉트론에서는 AND, OR 연산에 대한 학습이 가능하지만, XOR은 불가능하다.

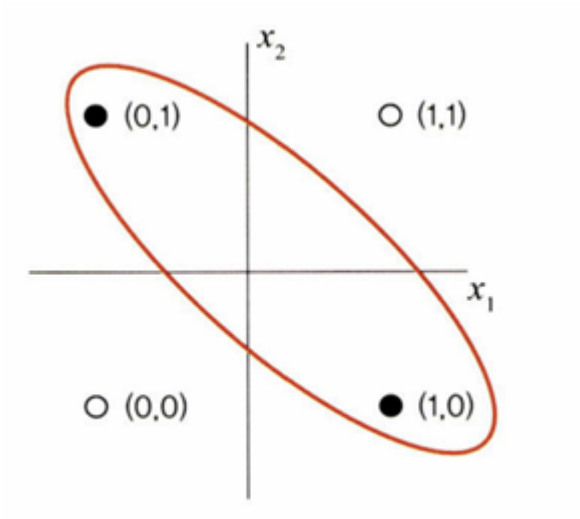

이를 극복하기 위해 다층 퍼셉트론(입력층과 출력층 사이에 하나 이상의 중간층(은닉층)을 두어 비선형적으로 분리되는 데이터도 학습이 가능)을 고안했다.

심층 신경망(Deep Neural Network): 입력층과 출력층 사이에 은닉층이 여러 개 있는 신경망. 딥러닝이라고도 한다.

4.2 딥러닝 구조

4.2.1 딥러닝 용어

딥러닝은 입력층, 출력층, 두 개 이상의 은닉층으로 구성되어 있다.

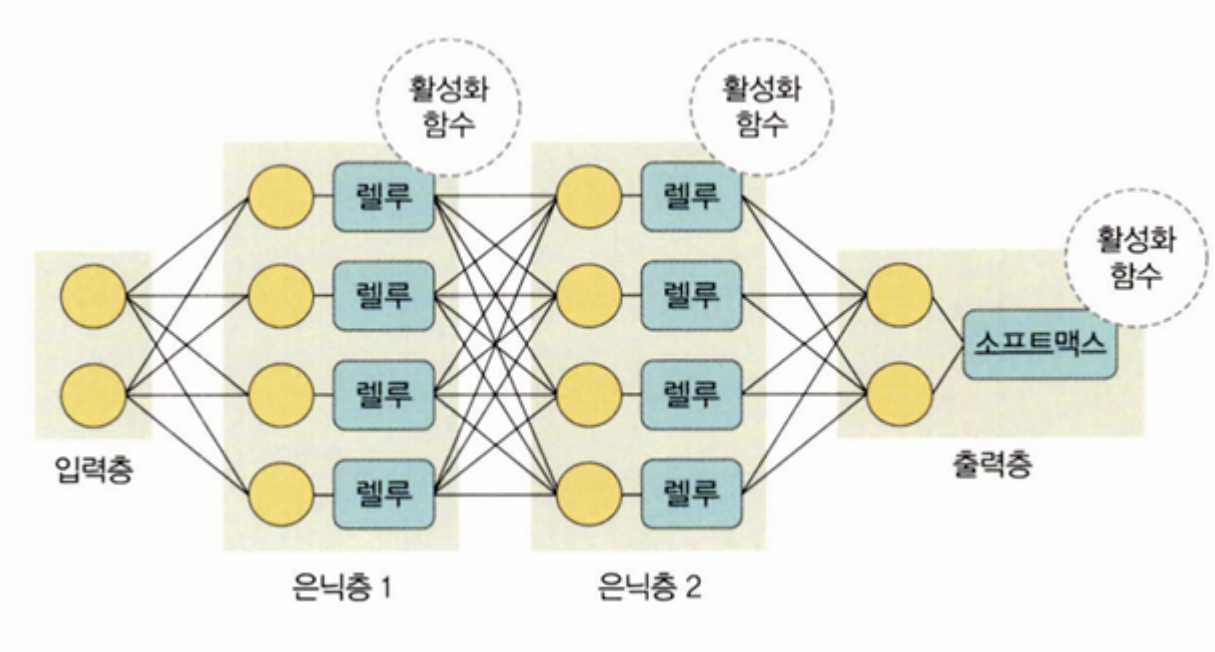

딥러닝을 구성하는 요소들:

구분	구성 요소	설명
층	입력층(input layer)	데이터를 받아들이는 층
	은닉층(hidden layer)	모든 입력 노드부터 입력 값을 받아 가중합을 계산하고, 이 값을 활성화 함수에 적용하여 출력층에 전달하는 층
	출력층(output layer)	신경망의 최종 결괏값이 포함된 층

구분	구성 요소	설명
가중치(weight)		노드와 노드 간 연결 강도
바이어스(bias)		가중합에 더해 주는 상수로, 하나의 뉴런에서 활성화 함수를 거쳐 최종적으로 출력되는 값을 조절하는 역할을 함
가중합(weighted sum), 전달 함수		가중치와 신호의 곱을 합한 것
함수	활성화 함수(activation function)	신호를 입력받아 이를 적절히 처리하여 출력해 주는 함수
	손실 함수(loss function)	가중치 학습을 위해 출력 함수의 결과와 실제 값 간의 오차를 측정하는 함수

가중치 : 입력 값이 연산 결과에 미치는 영향력을 조절하는 요소

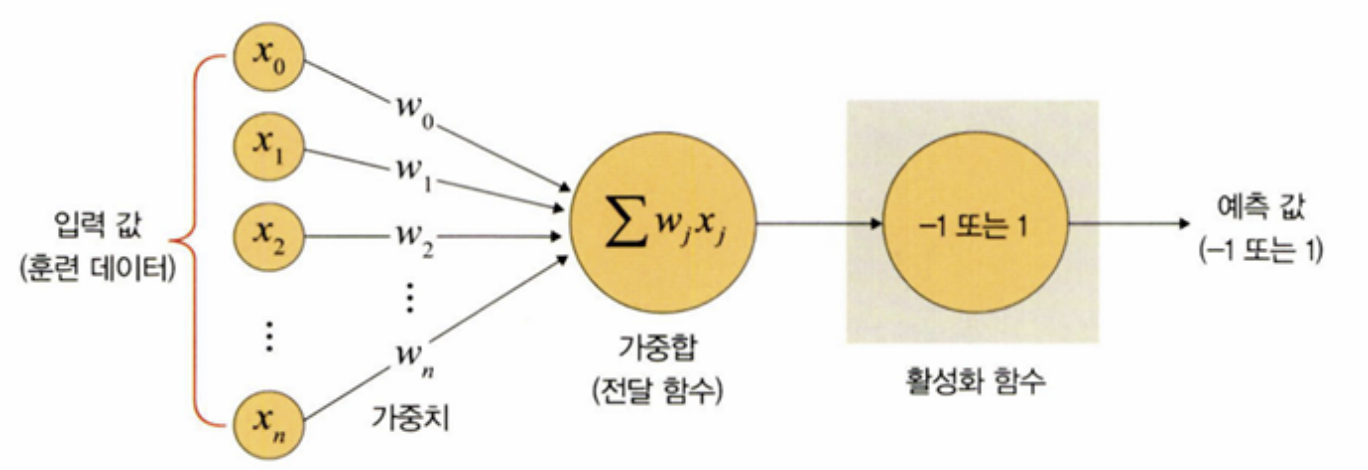

가중합 또는 전달 함수 : 각 노드에서 들어오는 신호에 가중치가 곱해져 다음 노드로 전달되는데, 이 값들을 모두 더한 총계. 가중합을 활성화 함수로 보내기 때문에 전달 함수라고 불리기도 한다.

가중합을 구하는 공식:

$$\sum_i w_i x_i + b$$

(w: 가중치, b: 바이어스)

활성화 함수 : 전달 함수에서 전달받은 값을 출력할 때 일정 기준에 따라 출력 값을 변화시키는 **비선형 함수**. 활성화 함수로는 시그모이드, 하이퍼볼릭 탄젠트, 렐루 함수 등이 있다.

1. 시그모이드 함수
   선형 함수의 결과를 0~1 사이에서 비선형 형태로 변형해 준다. 주로 로지스틱 회귀와 같은 분류 문제를 확률적으로 표현하는 데 사용된다. 딥러닝 모델의 깊이가 깊어지면 기울기가 사라지는 '기울기 소멸 문제'가 발생하여 딥러닝 모델에서는 잘 사용하지 않는다.

$$f(x) = \frac{1}{1+e^{-x}}$$

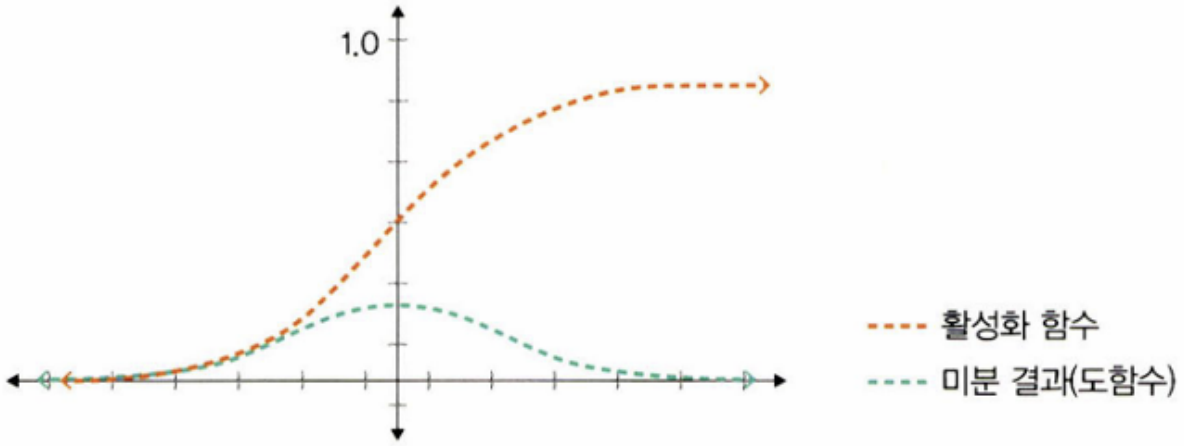

2. 하이퍼볼릭 탄젠트 함수
   선형 함수 결과를 -1~1 사이에서 비선형 상태로 변형해 준다. 시그모이드에서 결괏값의 평균이 0이 아닌 양수로 편향되는 문제를 해결하는 데 사용했지만, 여전히 기울기 소멸 문제 발생.

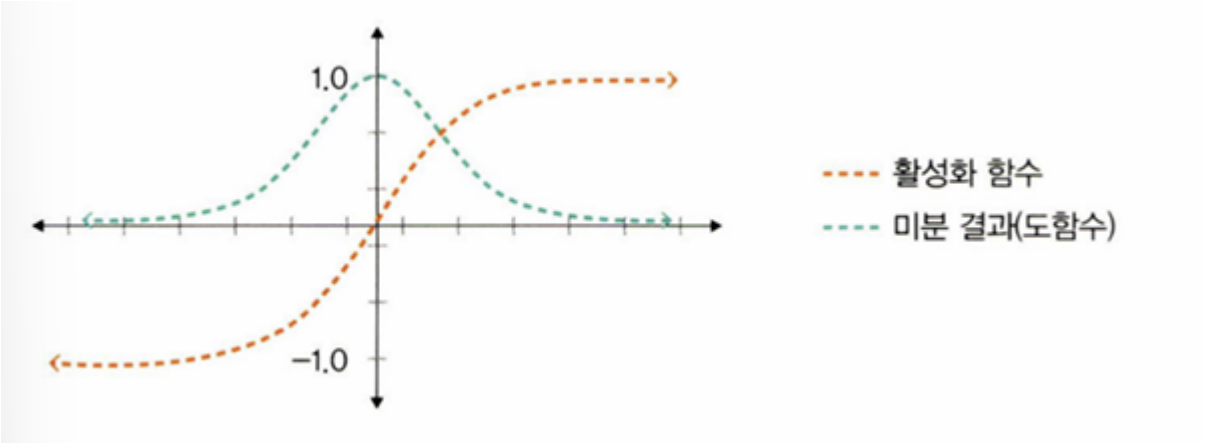

3. 렐루 함수

최근 활발히 사용된다. 입력이 음수일 때는 0, 양수일 때는 x를 출력한다. (y=x) 경사 하강법에 영향을 주지 않아 학습 속도가 빠르고 기울기 소멸 문제가 발생하지 않는다. 일반적으로 **은닉층**에 사용되며, 하이퍼볼릭 탄젠트 함수 대비 학습 속도가 6배 빠르다. 문제는 음수 값을 입력받으면 항상 0을 출력하기 때문에 학습 능력이 감소하는데, 이를 해결하기 위해 리키 렐루(Leaky ReLU) 함수 등을 사용한다.

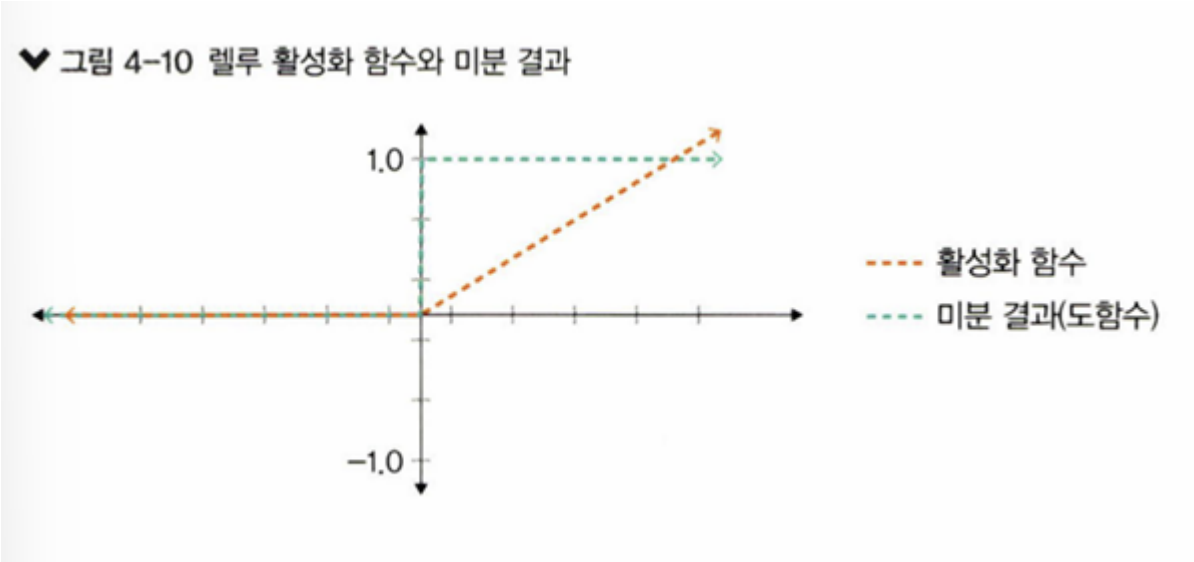

4. 리키 렐루 함수

입력 값이 음수면 0이 아닌 0.001처럼 매우 작은 수를 반환한다. 이렇게 하면 입력 값이 수렴하는 구간이 제거되어 렐루 함수를 사용할 때 생기는 문제를 해결할 수 있다.

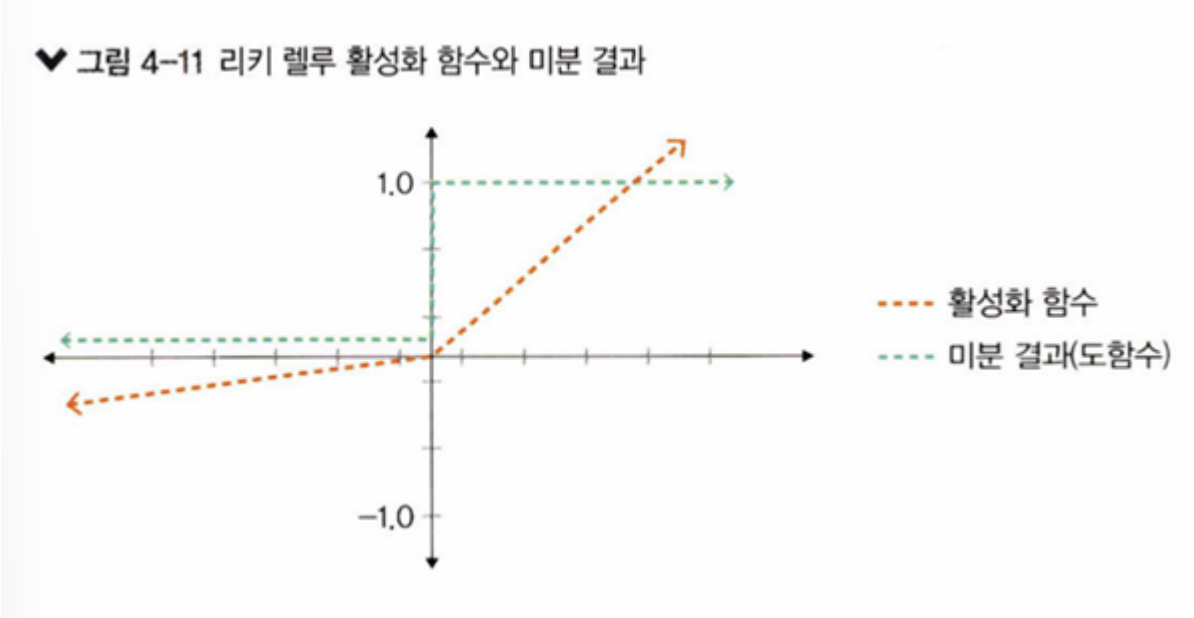

5. 소프트맥스 함수

입력 값을 0~1 사이에 출력되도록 정규화하여 출력 값들의 총합이 항상 1이 되도록 한다. 보통 딥러닝에서 출력 노드의 활성화 함수로 많이 사용된다.

$$y_k = \frac{\exp(a_k)}{\sum_{i=1}^{n} \exp(a_i)}$$

손실 함수

경사 하강법: 학습률(learning rate)과 손실 함수의 순간 기울기를 이용하여 가중치를 업데이트하는 방법. 즉, 미분의 기울기를 이용하여 오차를 비교하고 최소화하는 방향으로 이동시키는 방법. 이때 오차를 구하는 방법이 손실 함수.

손실 함수 값이 클수록 많이 틀렸다는 의미이고, 값이 0에 가까우면 완벽하게 추정할 수 있다는 의미이다. 대표적인 손실 함수로 평균 제곱 오차(MSE)와 크로스 엔트로피 오차(CEE)가 있다.

1. 평균 제곱 오차
   실제 값과 예측 값의 차이를 제곱하여 평균 낸 것. 회귀에서 주로 사용된다.

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

$$\left(\begin{array}{l} \hat{y}_i\text{: 신경망의 출력(신경망이 추정한 값)} \\ y_i\text{: 정답 레이블} \\ i\text{: 데이터의 차원 개수} \end{array}\right)$$

2. 크로스 엔트로피 오차
   분류 문제에서 원-핫 인코딩했을 때만 사용 가능. 일반적으로 분류 문제에서는 시그모이드 함수를 사용하는데, 시그모이드 함수에 포함된 자연 상수 e 때문에 평균 제곱 오차를 적용하면 매끄럽지 못한 그래프가 출력된다. 따라서 크로스 엔트로피 손실 함수를 사용하는데, 이 손실 함수를 적용할 경우 경사 하강법 과정에서 학습이 지역 최소점에서 멈출 수 있다. 이를 방지하기 위해 자연 상수 e에 반대되는 자연 로그를 모델의 출력 값에 취한다.

$$CrossEntropy = -\sum_{i=1}^{n} y_i \log \hat{y}_i$$

$$\left(\begin{array}{l} \hat{y}_i\text{: 신경망의 출력(신경망이 추정한 값)} \\ y_i\text{: 정답 레이블} \\ i\text{: 데이터의 차원 개수} \end{array}\right)$$

4.2.2 딥러닝 학습

딥러닝 학습은 크게 순전파와 역전파라는 두 단계로 진행된다.

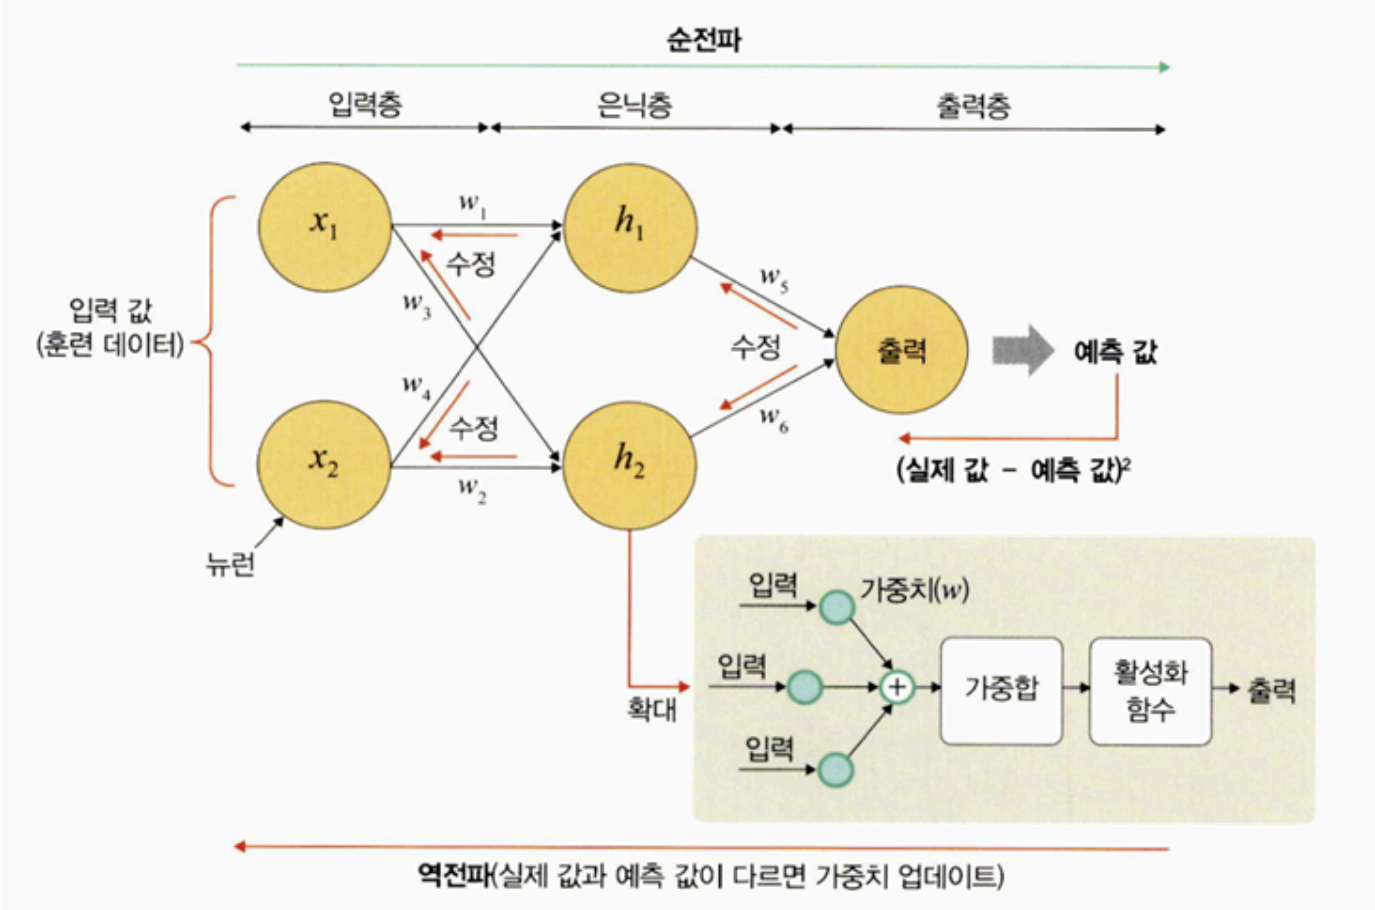

순전파

네트워크에 훈련 데이터가 들어올 때 발생하며, 데이터를 기반으로 예측 값을 계산하기 위해 전체 신경망을 교차해 지나간다. 즉, 모든 뉴런이 이전 층의 뉴런에서 수신한 정보에 변환(가중합 및 활성화 함수)을 적용하여 다음 층(은닉층)의 뉴런으로 전송하는 방식이다. 네트워크를 통해 입력 데이터를 전달하며, 데이터가 모든 층을 통과하고 모든 뉴런이 계산을 완료하면 그 예측 값은 최종 층인 출력층에 도달하게 된다.

역전파

그다음 손실 함수로 네트워크의 예측 값과 실제 값의 차이(손실, 오차)를 추정한다. 이때 손실 함수 비용은 0이 이상적이다. 따라서 손실 함수 값이 0에 가까워지도록 하기 위해 훈련을 반복하면서 가중치를 조정한다. 손실(오차)이 계산되면 그 정보는 역으로 전파(출력층 -> 은닉층 -> 입력층)되기 때문에 역전파라고 한다. 출력층에서 시작된 손실 비용은 은닉층의 모든 뉴런으로 전파되지만, 은닉층의 뉴런은 각 뉴런이 원래 출력에 기여한 상대적 기여도에 따라(즉, 가중치에 따라) 값이 달라진다. 예측 값과 실제 값 차이를 각 뉴런의 가중치로 미분한 후 기존 가중치 값에서 뺀다. 이 과정을 출력층 -> 은닉층 -> 입력층 순서로 모든 뉴런에 대해 진행해 계산된 각 뉴런의 결과를 다시 순전파의 가중치 값으로 사용한다.

4.2.3 딥러닝의 문제점과 해결 방안

활성화 함수가 적용된 은닉층 개수가 많을수록 데이터 분류가 잘 된다. 하지만 은닉층이 많을수록 다음 세 가지 문제가 발생한다.

과적합 문제 발생

과적합: 훈련 데이터를 과하게 학습해서 발생한다. 훈련 데이터에 대한 정확도는 높지만, 검증 데이터에 대해서는 오차가 증가할 수 있다.

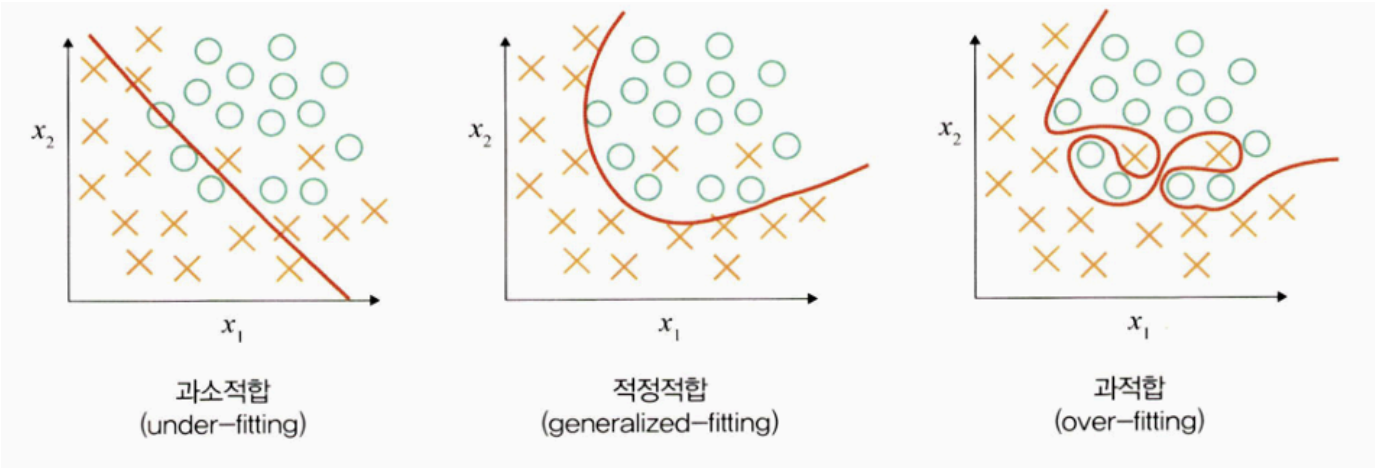

과적합을 해결하는 방법으로 드롭아웃(dropout)이 있다. 이는 학습 과정 중 임의로 일부 노드들을 학습에서 제외시키는 것을 의미한다.

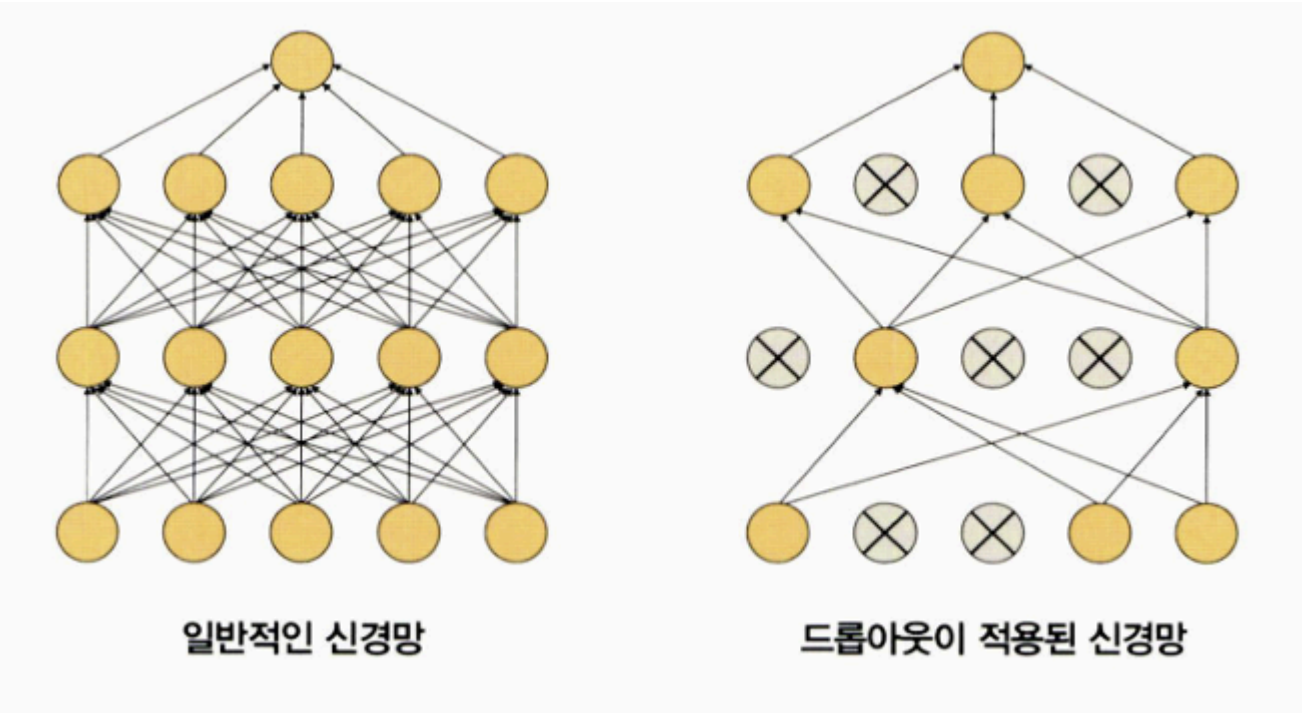

기울기 소멸 문제 발생

출력층에서 은닉층으로 전달되는 오차가 크게 줄어들어 학습이 되지 않는 현상이다. 즉, 기울기가 소멸되어 학습되는 양이 0에 가까워짐에 따라 학습이 더디게 진행되다 오차를 더 줄이지 못하고 그 상태로 수렴하는 현상이다. 기울기 소멸 문제는 시그모이드나 하이퍼볼릭 탄젠트 대신 렐루를 사용하면 해결할 수 있다.

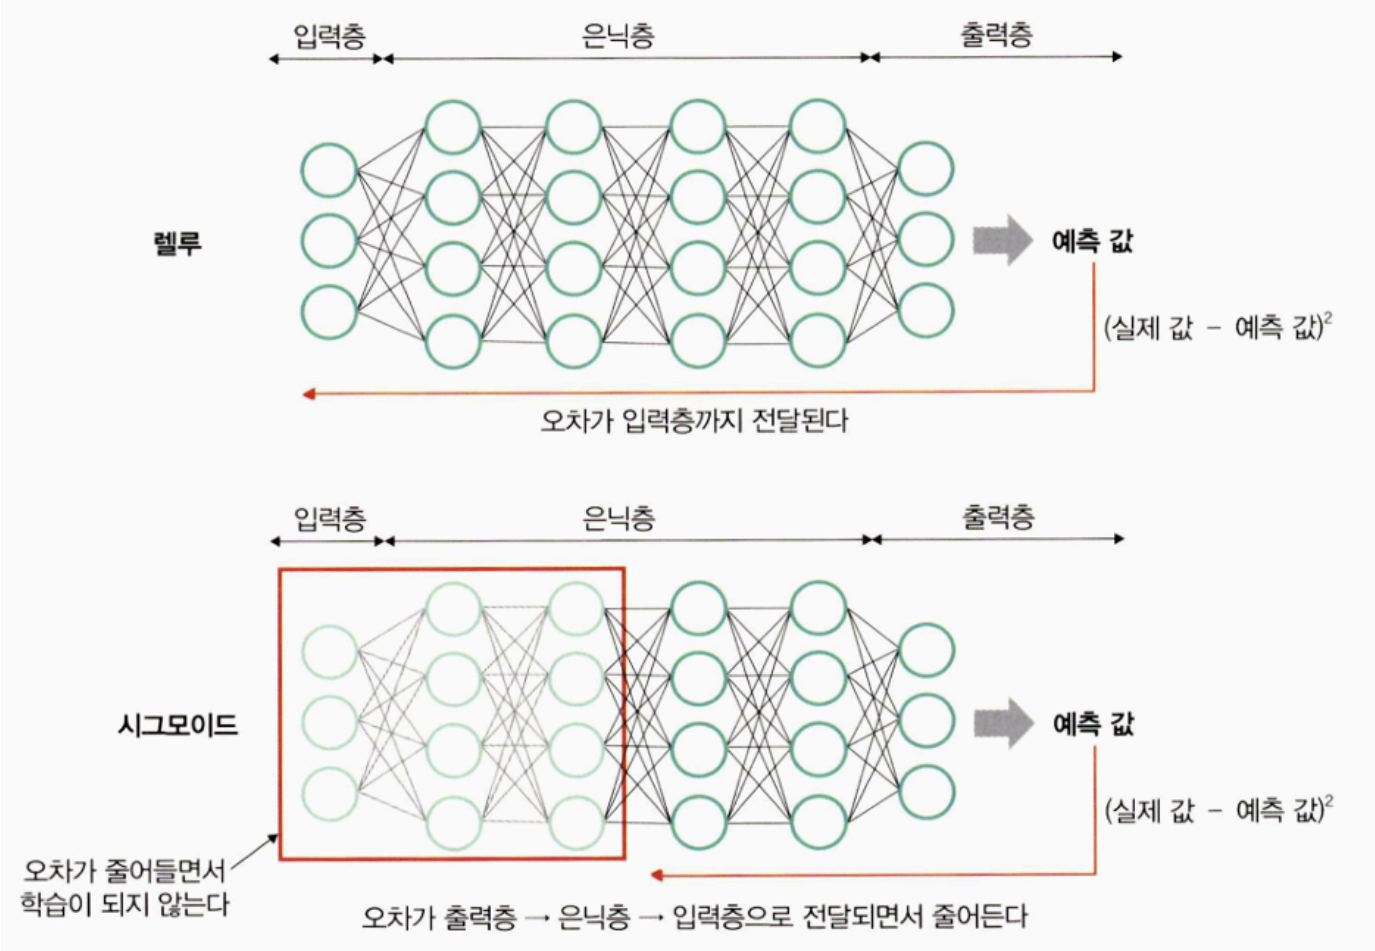

성능이 나빠지는 문제 발생

경사 하강법은 손실 함수의 비용이 최소가 되는 점을 찾을 때까지 기울기가 낮은 쪽으로 계속 이동시키는 과정을 반복하는데, 이때 성능이 나빠지는 문제가 발생한다. 이 문제를 개선하기 위해 확률적 경사 하강법과 미니 배치 하강법을 사용한다.

1. 배치 경사 하강법

   전체 데이터셋에 대한 오류를 구한 후 기울기를 한 번만 계산하여 모델의 파라미터를 업데이트하는 방법. 즉, 전체 훈련 데이터셋에 대해 가중치를 편미분하는 방법이다. 한 스텝에 모든 훈련 데이터셋을 사용하므로 학습이 오래 걸리는 단점이 있다.

2. 확률적 경사 하강법

임의로 선택한 데이터에 대해 기울기를 계산하는 방법으로 적은 데이터를 사용하므로 빠른 계산이 가능하다. 파라미터 변경 폭이 불안정하고, 때로는 배치 경사 하강법보다 정확도가 낮을 수 있지만 속도가 빠르다는 장점이 있다.

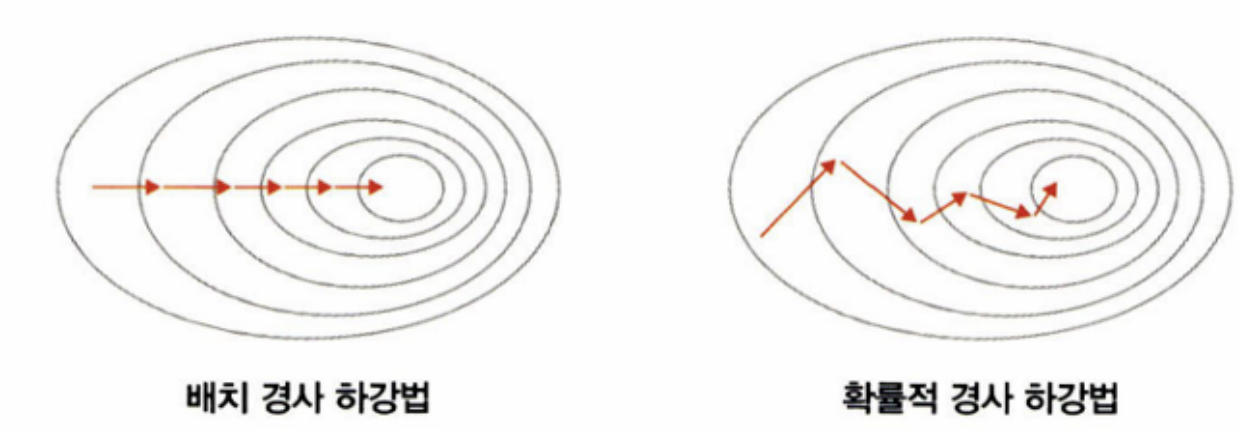

3. 미니 배치 경사 하강법

전체 데이터셋을 미니 배치 여러 개로 나누고, 미니 배치 한 개마다 기울기를 구한 후 그것의 평균 기울기를 이용하여 모델을 업데이트해서 학습하는 방법.

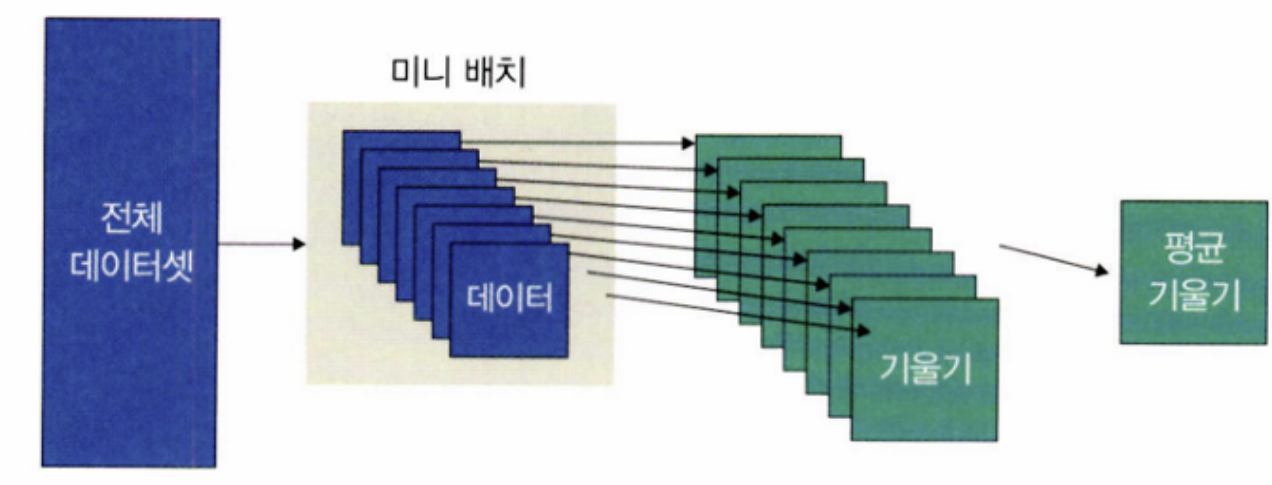

전체 데이터를 계산하는 것보다 빠르며, 확률적 경사 하강법보다 안정적이라는 장점이 있기 때문에 실제로 가장 많이 사용한다.

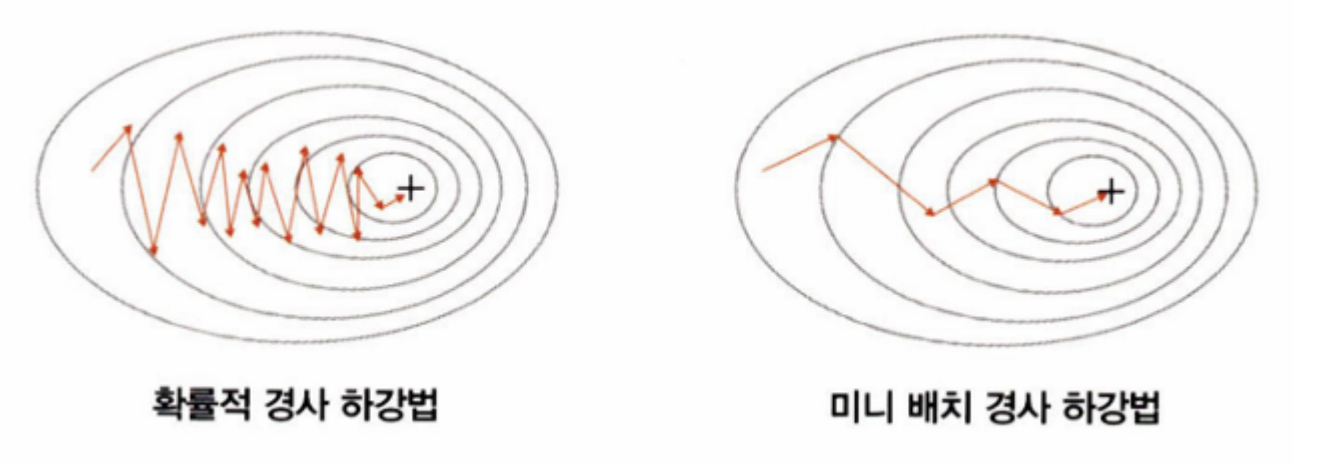

옵티마이저

확률적 경사 하강법의 파라미터 변경 폭 불안정 문제를 해결하기 위해 학습 속도와 운동량을 조정하는 옵티마이저(optimizer)를 적용해 볼 수 있다.

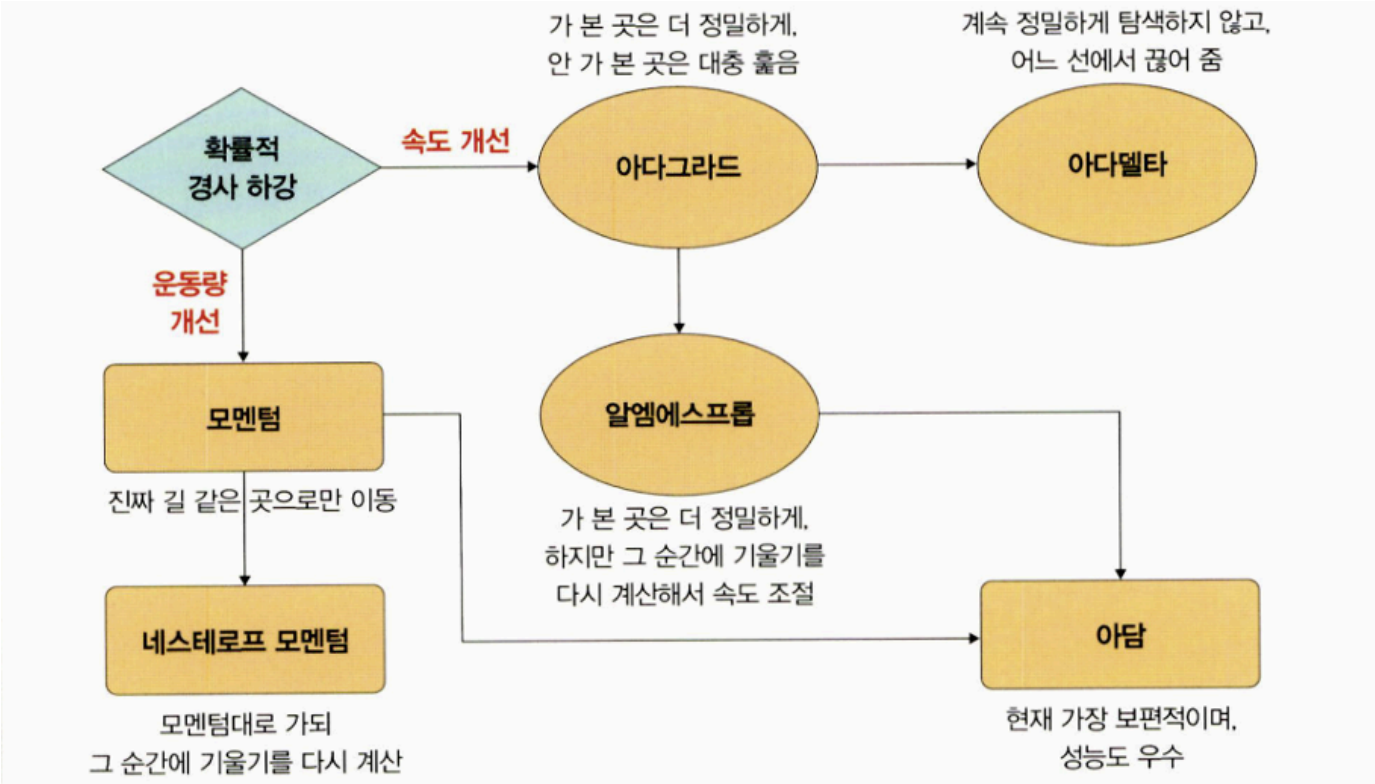

속도를 조정하는 방법

1. 아다그라드

   변수(가중치)의 업데이트 횟수에 따라 학습률을 조정하는 방법. 많이 변화하지 않는 변수들의 학습률은 크게 하고, 많이 변화하는 변수들의 학습률은 작게 한다. 즉, 많이 변화한 변수는 최적 값에 근접했을 것이라는 가정하에 작은 크기로 이동하면서 세밀하게 값을 조정하고, 반대로 적게 변화한 변수들은 학습률을 크게 하여 빠르게 오차 값을

줄이고자 한다. 하지만 아다그라드는 기울기가 0에 수렴하는 문제가 있어 사용하지 않으며, 대신에 알엠에스프롭을 사용한다.

2. 아다델타
   아다그라드에서 G 값이 커짐에 따라 학습이 멈추는 문제를 해결하기 위해 등장한 방법.

3. 알엠에스프롭
   아다그라드의 G(i) 값이 무한히 커지는 것을 방지하고자 제안된 방법.

운동량을 조정하는 방법

1. 모멘텀
   경사 하강법과 마찬가지로 매번 기울기를 구하지만, 가중치를 수정하기 전에 이전 수정 방향(+, -)을 참고하여 같은 방향으로 일정한 비율만 수정하는 방법이다. 수정이 양의 방향과 음의 방향으로 순차적으로 일어나는 지그재그 현상이 줄어들고, 이전 이동 값을 고려하여 일정 비율만큼 다음 값을 결정하므로 관성 효과를 얻을 수 있는 장점이 있다. 모멘텀은 확률적 경사 하강법과 함께 사용한다. momentum 값은 0.9에서 시작하며 0.95, 0.99처럼 조금씩 증가시키면서 사용한다.

2. 네스테로프 모멘텀
   모멘텀 값과 기울기 값이 더해져 실제 값을 만드는 기존 모멘텀과 달리 모멘텀 값이 적용된 지점에서 기울기 값을 계산한다. 모멘텀 방법은 멈추어야 할 시점에서도 관성에 의해 훨씬 멀리 갈 수 있는 단점이 있지만, 네스테로프 방법은 모멘텀에서 절반 정도 이동한 후 어떤 방식으로 이동해야 하는지 다시 계산하여 결정하기 때문에 모멘텀 방법의 단점을 극복할 수 있다. 따라서 모멘텀 방법의 이점인 빠른 이동 속도는 그대로 가져가면서 멈추어야 할 적절한 시점에서 제동을 거는 데 훨씬 용이하다.

속도와 운동량에 대한 혼용 방법

아담(Adam)

모멘텀과 알엠에스프롭의 장법을 결합한 경사 하강법이다. 학습률 기본값은 1e-3이다.

4.2.4 딥러닝을 사용할 때 이점

1. 특성 추출
   컴퓨터가 입력받은 데이터를 분석하여 일정한 패턴이나 규칙을 찾아내려면 사람이 인지하는 데이터를 컴퓨터가 인지할 수 있는 데이터로 변환해 주어야 한다. 이때 데이터별로 어떤 특징을 가지고 있는지 찾아내고, 그것을 토대로 데이터를 벡터로 변환하는 작업을 특성 추출이라고 한다. 딥러닝이 활성화되기 전에 많이 사용되던 머신 러닝 알고리즘의 특성 추출은 매우 복잡하며 수집된 데이터에 대한 전문 지식이 필요했다. 하지만 딥러닝에서는 은닉층을 깊게 쌓는 방식으로 파라미터를 늘려서 이러한 특성 추출 과정을 알고리즘에 통합시켰다.

2. 빅데이터의 효율적 활용
   딥러닝 학습을 이용한 특성 추출은 데이터 사례가 많을수록 성능이 향상된다.
   즉, 확보된 데이터가 적다면 딥러닝의 성능 향상을 기대하기 힘들기 때문에 머신러닝을 고려해 봐야 한다.

4.3 딥러닝 알고리즘

딥러닝 알고리즘은 심층 신경망을 사용한다는 공통점이 있다. 목적에 따라 합성곱 신경망(CNN), 순환 신경망(RNN), 제한된 볼츠만 머신(RBM), 심층 신뢰 신경망(DBN)으로 분류된다.

4.3.1 심층 신경망

심층 신경망(DNN)은 입력층과 출력층 사이에 다수의 은닉층을 포함하는 인공 신경망이다.
다수의 은닉층을 두었기 때문에 다양한 비선형적 관계를 학습할 수 있는 장점이 있지만, 학습을 위한 연산량이 많고 기울기 소멸 문제 등이 발생할 수 있다. 이러한 문제를 해결하고자 드롭아웃, 렐루 함수, 배치 정규화 등을 적용해야 한다.

4.3.2 합성곱 신경망

합성곱 신경망(CNN)은 합성곱층과 풀링층을 포함하는 이미지 처리 성능이 좋은 인공 신경망 알고리즘이다. 영상 및 사진이 포함된 이미지 데이터에서 객체를 탐색하거나 객체 위치를 찾아내는 데 유용하다. 대표적인 합성곱 신경망으로 LeNet-5와 AlexNet이 있다. 층을 더 깊게 쌓은 신경망으로는 VGG, GoogLeNet, ResNet 등이 있다. 기존 신경망과 비교하여 다음과 같은 차별성이 있다.

- 각 층의 입출력 형상을 유지한다.
- 이미지의 공간 정보를 유지하며 인접 이미지와 차이가 있는 특징을 효과적으로 인식한다.
- 복수 필터로 이미지의 특징을 추출하고 학습한다.
- 추출한 이미지의 특징을 모으고 강화하는 풀링층이 있다.
- 필터를 공유 파라미터로 사용하기 때문에 일반 인공 신경망과 비교하여 학습 파라미터가 매우 적다.

4.3.3 순환 신경망

순환 신경망(RNN)은 시계열 데이터(음악, 영상 등) 같은 시간 흐름에 따라 변화하는 데이터를 학습하기 위한 인공 신경망이다. 순환은 자기 자신을 참조한다는 뜻으로, 현재 결과가 이전 결과와 연관이 있다는 의미이다.

순환 신경망의 특징은 다음과 같다.

- 시간성을 가진 데이터가 많다.

- 시간성 정보를 이용하여 데이터의 특징을 잘 다룬다.
- 시간에 따라 내용이 변하므로 데이터는 동적이고, 길이가 가변적이다.
- 매우 긴 데이터를 처리하는 연구가 활발히 진행되고 있다.

순환 신경망은 기울기 소멸 문제로 학습이 제대로 되지 않는 문제가 있다. 이를 해결하고자 메모리 개념을 도입한 LSTM이 순환 신경망에서 많이 사용되고 있다. 순환 신경망은 자연어 처리 분야(언어 모델링, 텍스트 생성, 자동/기계 번역, 음성 인식, 이미지 캡션 생성)에 사용된다.

4.3.4 제한된 볼츠만 머신

볼츠만 머신은 가시층과 은닉층으로 구성된 모델이다. 가시층이 은닉층과만 연결되는 모델이 제한된 볼츠만 머신이다.

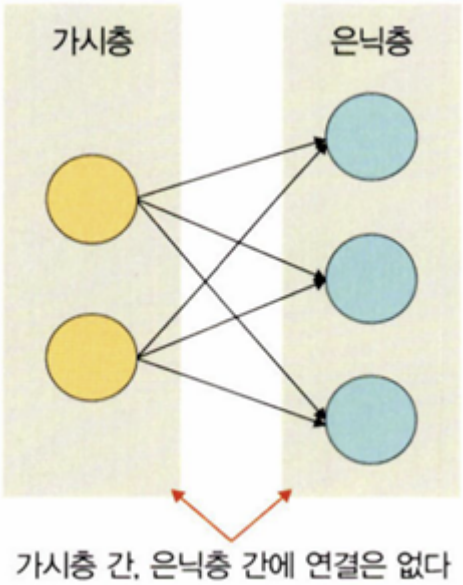

제한된 볼츠만 머신의 특징은 다음과 같다.

- 차원 감소, 분류, 선형 회귀 분석, 협업 필터링, 특성 값 학습, 주제 모델링에 사용한다.
- 기울기 소멸 문제를 해결하기 위해 사전 학습 용도로 활용 가능하다.
- 심층 신뢰 신경망(DBN)의 요소로 활용된다.

딥러닝에서 많이 사용되는 알고리즘은 CNN과 RNN으로, 제한된 볼츠만 머신과 심층 신뢰 신경망은 상대적으로 많이 사용하지 않는다.

4.3.5 심층 신뢰 신경망

심층 신뢰 신경망은 입력층과 은닉층으로 구성된 제한된 볼츠만 머신을 블록처럼 여러 층으로 쌓은 형태로 연결된 신경망이다. 레이블이 없는 데이터에 대한 비지도 학습이 가능하다.
부분적인 이미지에서 전체를 연상하는 일반화와 추상화 과정을 구현할 때 사용하면 유용하다.

심층 신뢰 신경망의 학습 절차:

1. 가시층과 은닉층 1에 제한된 볼츠만 머신을 사전 훈련한다.
2. 첫 번째 층 입력 데이터와 파라미터를 고정하여 두 번째 층 제한된 볼츠만 머신을 사전 훈련한다.
3. 원하는 층 개수만큼 제한된 볼츠만 머신을 쌓아 올려 전체 DBN을 완성한다.

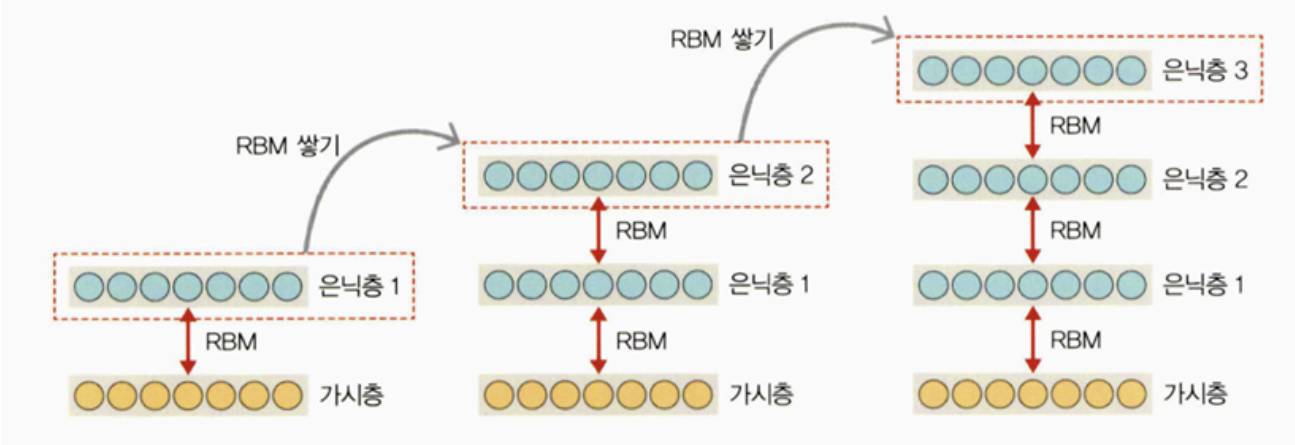

심층 신뢰 신경망의 특징은 다음과 같다.

- 순차적으로 심층 신뢰 신경망을 학습시켜가면서 계층적 구조를 생성한다.
- 비지도 학습으로 학습한다.
- 위로 올라갈수록 추상적 특성을 추출한다.
- 학습된 가중치를 다층 퍼셉트론의 가중치 초깃값으로 사용한다.

4.4 우리는 무엇을 배워야 할까?

간단한 선형 회귀 분류를 이용하여 원하는 값을 도출할 수 있다면 머신 러닝만으로도 충분하지만, 복잡한 비선형 데이터에 대한 분류 및 예측을 도출하고 싶다면 딥러닝으로 학습해야 한다.

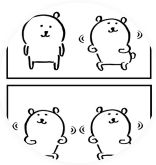

카사바

안녕하세요 :)

이전 포스트
Week1_예습과제

0개의 댓글

댓글을 작성하세요

댓글 작성

Powered by
Stellate