


## 5.3 전이 학습

큰 데이터셋 학습에 있는 어려움을 해결하기 위해 ImageNet과 같은 아주 큰 데이터셋(사전에 아주 큰 데이터셋으로 훈련된 모델)을 써서 훈련된 모델의 가중치를 가져와 실제로 해결하려는 과제에 맞게 보정해서 사용하는 것

▼ 그림 5-29 전이 학습



전이 학습을 위한 방법: 특성 추출 방법, 미세 조정 기법

### 5.3.1 특성 추출 기법

사전 훈련된 모델을 가져온 후 마지막에 완전 연결층 부분만 새로 생성.


학습할 때: 마지막 완전연결층만 학습하고 나머지 계층 학습 할 필요 없음

특성 추출 - 합성곱층: 합성곱층+풀링층

- 데이터 분류기(완전연결층): 추출된 특성을 입력받아 최종적으로 이미지에 대한 클래스를 분류하는 부분

사전 훈련된 모델의 **합성곱층(가중치 고정)** 에 새로운 데이터 통과 -> 해당 데이터를 **분류기**에서 훈련

▼ 그림 5-30 특성 추출 기법



실습:

Dataset: 강아지, 고양이 이미지

사전 훈련된 모델: ResNet18

완전연결층 추가 후 완전연결층만 학습

모델 학습을 위한 함수 생성 후


ResNet18에 추가된 완전연결층 학습하도록 설계. 학습을 통해 얻어지는 파라미터를 옵티마이저에 전달해서 최종적으로 모델 학습에 사용

훈련과 테스트 모드 에포크를 진행할 수록 정확도가 높아지며 에포크가 더 많

① 역전파 중 파라미터들에 대한 변화를 계산할 필요가 없음을 나타냅니다. 즉, 모델의 일부를 고정하고 나머지를 학습하고자 할 때 `requires_grad = False`로 설정합니다. 이때 모델의 일부는 합성곱층(convolutional layer)과 풀링(pooling)층을 의미합니다.

내려받은 ResNet18의 마지막 부분에 완전연결층을 추가합니다. 추가된 완전연결층은 개와 고양이 클래스를 분류하는 용도로 사용됩니다.

▼ 그림 5-36 ResNet18에 완전연결층 추가



이 진행될수록 정확도가 높아질 것

### 5.3.2 미세 조정 기법

“사전 학습된 모델을 목적에 맞게 재학습시키거나 학습된 가중치의 일부를 재학습”

특성 추출 기법에서 더 나아가 사전 훈련된 모델과 합성곱층, 데이터 분류기의 가중치를 업데이트 하여 훈련시키는 방식.


특성 추출 방식: 목표 특성을 잘 추출했다는 전제하에 좋은 특성 -> if 특성 잘못 추출되면

이때 미세조정기법으로 새로운 이미지 데이터를 사용하여 네트워크의 가중치를 업데이트해서 특성을 다시 추출할 수 있음

데이터셋 크리&사전 훈련된 모델에 따라 전략


- 데이터셋 크고 사전 훈련된 모델과 유사x : 모델 전체 재학습
- 데이터셋 크고 사전 훈련된 모델과 유사o: 합성곱층의 뒷부분(완전연결층과 가까운) & 데이터 분류기 학습
- 데이터셋 작고 사전 훈련된 모델과 유사x : 합성곱층의 일부분&데이터분류기 학습. 데이터가 적기 때문에 미세 조정 기법 효과 미미
- 데이터셋 작고 사전 훈련된 모델과 유사o: 데이터 분류기만 학습, 데이터가 적기 때문에 미세조정기법은 과적합 발생 위험

♥ 그림 5-44 미세 조정 기법



## 5.4 설명 가능한 CNN

딥러닝 처리 결과를 사람이 이해할 수 있는 방식으로 제시하는 기술



CNN은 블랙박스 같은 특성 -> CNN결과를 신뢰하기 위해 처리 과정을 시각화  
: 특성에 대한 시각화, 맵에 대한 시각화

### 5.4.1 특성 맵 시각화

특성 맵(활성화 맵): 입력 이미지 또는 다른 특성 맵처럼 필터를 입력에 적용한 결과

특성 맵 시각화: 특성 맵에서 입력 특성을 감지하는 방법을 이해할 수 있도록 돕는 것  
 실습: 설명 가능한 네트워크 생성(13개의 합성곱층 & 2개의 완전연결층으로 구성)  
 해당 모델 객체화 후 GPU/CPU에 할당  
 특성 맵 확인하기 위한 클래스 정의: hook기능을 이용해서 각 계층의 활성화 함수 및 기울기 값 확인  
 register\_forward\_hook으로 순전파 중에 각 네트워크 모듈의 입력 및 출력 가져옴  
 이미지 호출 후 설정한 n번째의 Conv2d 특성 맵 확인  
 => 출력층에 가까울 수록 원래 형태가 나타나지 않으며 이미지 특징들만 남는것을 확인할 수 있음


## 5.5 그래프 합성곱 네트워크

그래프 데이터를 위한 신경망

### 5.5.1 그래프

방향성이 있거나 없는 에지로 연결된 노드의 집합  
 노드: 원소  
 에지: 결합방법(single, double, triple, aromatic)


▼ 그림 5-50 그래프



### 5.5.2 그래프 신경망

Graph Neural Network: 그래프 구조에서 사용하는 신경망  
 인접행렬과 특성행렬로 이를 표현할 수 있다.

1. 인접행렬: 아래 네트워크의 노드 n개를 nxn행렬로 표현  
 인접 행렬 내의 값  $A_{ij}$ 는 i와 j의 관련성 여부를 만족하는 값으로 채워 줌  
 => 컴퓨터가 이해하기 쉽게 그래프로 표현하는 과정  
 But, 인접 행렬만으로는 특성을 파악하기 어려움
2. 특성행렬: 각 입력 데이터에 이용할 특성 선택  
 각 행은 선택된 특성에 대해 각 노드가 갖는 값 의미  
 특성 행렬 과정을 거쳐 그래프의 특성 추출



### 5.5.3 그래프 합성곱 네트워크


Graph Convolutional Network : 이미지에 대한 합성곱을 그래프 데이터로 확장한 알고리즘

GCN활용 예시: SNS에서 관계 네트워크

학술 연구에서 인용 네트워크

3D Mesh

합성곱 네트워크 구조:



리드아웃: 특성 행렬을 하나의 벡터로 변환하는 함수  
전체 노드의 특성 벡터에 대한 평균을 구해  
-> 그래프 전체를 표현하는 하나의 벡터 생성

그래프 합성곱층: GCN에서 가장 중요한 부분.  
그래프 형태의 데이터 -> 행렬 형태  
데이터 변환 발생: 딥러닝 알고리즘 적용할 수 있게 됨