

week5_예습과제_김규리

▼ 6.1.1 LeNet-5

1. 개요 및 역사적 배경

- **개발자:** 1995년 얀 르쿤(Yann LeCun), 레옹 보토(Leon Bottu), 요슈아 벤지오(Yoshua Bengio), 패트릭 하프너(Patrick Haffner) 등이 발표.
- **목적:** 수표에 쓴 손글씨 숫자를 자동으로 인식하기 위한 알고리즘.
- **의의:** 합성곱 신경망(CNN)이라는 개념을 최초로 정립한 구조로, 현대 모든 CNN의 기초(초석)가 됨.

2. 핵심 구조적 특징

LeNet-5는 크게 **합성곱(Convolutional) 층**과 **다운 샘플링(Sub-sampling, 풀링) 층**을 반복적으로 거치며 특성을 추출하고, 마지막에 ****완전연결층(Fully Connected)****에서 분류를 수행합니다.

상세 계층 구조 (전통적 LeNet-5 기준)

1. **Input:** 32×32 이미지 (흑백).
2. **C1 (합성곱층):** 5×5 필터를 사용하여 28×28 크기의 특성 맵 6개를 생성.
3. **S2 (풀링층):** 다운 샘플링을 통해 특성 맵 크기를 14×14로 축소.
4. **C3 (합성곱층):** 5×5 필터로 10×10 크기의 특성 맵 16개를 생성.
5. **S4 (풀링층):** 다시 다운 샘플링하여 크기를 5×5로 축소.
6. **C5 (합성곱층):** 5×5 연산으로 1×1 크기의 특성 맵 120개를 생성 (사실상 FC층의 시작).
7. **F6 (완전연결층):** 84개의 유닛을 가진 층.
8. **Output:** 최종 10개의 카테고리(숫자 0~9)로 분류.

3. 교재 예제(개/고양이 분류)에서의 변형

교재에서는 224×224 크기의 컬러 이미지를 분류하기 위해 LeNet-5의 기본 철학을 유지하면서 파라미터를 조정하여 구현합니다.

출력 크기 계산 공식

- **합성곱층:** $\$(W - F + 2P) / S + 1\$$
 - $\$W\$$: 입력 크기, $\$F\$$: 커널 크기, $\$P\$$: 패딩, $\$S\$$: 스트라이드
- **풀링층:** $\$InputSize / KernelSize\$$ (스트라이드가 커널 크기와 같을 때)

데이터 전처리 원칙

- **Resize:** 모델 입력 규격에 맞게 조정.
- **Normalize:** 평균 $(0.485, 0.456, 0.406)$ 과 표준편차 $(0.229, 0.224, 0.225)$ 를 사용하여 데이터 분포를 일정하게 유지.
- **ToTensor:** PIL 이미지를 PyTorch 텐서로 변환하며 픽셀값을 $[0, 1]$ 범위로 스케일링.

▼ 6.1.2 AlexNet

1. 개요 및 의의

- **발표:** 2012년 알렉스 크리제브스키(Alex Krizhevsky) 등이 발표.
- **성과:** 이미지넷(ImageNet) 이미지 분류 대회(ILSVRC 2012)에서 압도적인 성적으로 우승하며 딥러닝 열풍을 일으킴.
- **특징:** GPU를 사용한 병렬 연산과 다양한 학습 기법을 도입하여 신경망을 더 깊고 넓게 설계함.

2. 핵심 기술적 특징

AlexNet은 성능 향상을 위해 다음과 같은 혁신적인 기법들을 도입했습니다.

- **ReLU 활성화 함수:** 기존의 Sigmoid나 Tanh 대신 ReLU를 사용하여 학습 속도를 6배 이상 향상시키고 기울기 소실(Gradient Vanishing) 문제를 완화함.
- **드롭아웃(Dropout):** 과적합(Overfitting)을 방지하기 위해 훈련 중 무작위로 일부 뉴런을 생략하여 학습함.
- **중첩 최대 풀링(Overlapping Max Pooling):** 커널 크기보다 스트라이드를 작게 설정하여 특성 맵의 손실을 줄이고 과적합을 방지함.
- **LRN(Local Response Normalization):** 강하게 활성화된 뉴런이 주변 뉴런의 반응을 억제하는 측면 억제(Lateral Inhibition) 효과를 모방하여 정규화 수행.
- **데이터 증강(Data Augmentation):** 이미지 반전, 무작위 자르기 등을 통해 훈련 데이터의 양을 인위적으로 늘려 일반화 성능을 높임.

3. 상세 계층 구조

총 8개의 층(5개의 합성곱층 + 3개의 완전연결층)으로 구성됩니다.

1. **Input**: $227 \times 227 \times 3$ (컬러 이미지).
2. **Conv1**: 11×11 커널, 스트라이드 4. (96개 필터)
3. **Max Pool 1**: 3×3 커널, 스트라이드 2.
4. **Conv2**: 5×5 커널, 패딩 2. (256개 필터)
5. **Max Pool 2**: 3×3 커널, 스트라이드 2.
6. **Conv3, 4, 5**: 3×3 커널을 연속으로 사용.
7. **Max Pool 3**: 3×3 커널, 스트라이드 2.
8. **FC6, FC7**: 각각 4096개의 뉴런을 가진 완전연결층.
9. **Output (FC8)**: Softmax를 통해 1,000개의 클래스로 분류.

▼ 6.1.3 VGGNet

1. 개요 및 특징

- **발표**: 2014년 옥스퍼드 대학의 시각 기하학 그룹(Visual Geometry Group, VGG)에서 개발.
- **핵심 철학**: "네트워크를 깊게 만들기 위해 아주 작은 3×3 커널만을 사용하자"는 것.
- **의의**: 합성곱층의 파라미터 수를 줄이면서도 신경망의 깊이를 16층~19층까지 깊게 쌓아 성능을 대폭 향상시킴.

2. 왜 3×3 커널인가?

- **비선형성 증가**: 3×3 커널을 세 번 쌓는 것은 7×7 커널 한 번과 동일한 수용 영역(Receptive Field)을 가지지만, 활성화 함수(ReLU)를 더 많이 거치게 되어 더 복잡한 특징을 학습할 수 있음.
- **파라미터 감소**: 7×7 커널 하나를 쓸 때보다 3×3 커널 세 개를 쓸 때 연산에 필요한 파라미터 수가 약 45% 가량 줄어듦. (연산 효율성 증대)

3. VGG16의 구조

교재에서 주로 다루는 VGG16 모델은 13개의 합성곱층과 3개의 완전연결층으로 구성됩니다.

1. **Block 1**: 3×3 Conv (64개) $\times$ 2 + Max Pool
2. **Block 2**: 3×3 Conv (128개) $\times$ 2 + Max Pool
3. **Block 3**: 3×3 Conv (256개) $\times$ 3 + Max Pool

4. **Block 4:** 3×3 Conv (512개) $\times$ 3 + Max Pool

5. **Block 5:** 3×3 Conv (512개) $\times$ 3 + Max Pool

6. **Classifier:** FC (4096) $\rightarrow$ FC (4096) $\rightarrow$ Output (1000)

- **참고:** 모든 합성곱층의 패딩(Padding)은 1로 설정하여 이미지 크기를 유지하고, 최대 풀링(Max Pooling)을 통해서만 크기를 절반으로 줄여나갑니다.

▼ 6.1.4 GoogLeNet

1. 개요 및 의의

- **발표:** 2014년 구글(Google)에서 개발. (ILSVRC 2014 우승)
- **핵심 혁신:** 네트워크를 단순히 깊게 쌓는 것보다 **폭(Width)을 넓게** 가지는 구조를 제안함.
- **특징:** 22개의 깊은 층으로 구성되어 있지만, AlexNet(파라미터 약 6천만 개)보다 훨씬 적은 파라미터(약 7백만 개)를 사용하여 효율적임.

2. 인셉션 모듈 (Inception Module)

네트워크의 한 계층에서 다양한 크기의 합성곱을 병렬로 수행하는 블록입니다.

- **구성:** 1×1 합성곱, 3×3 합성곱, 5×5 합성곱, 3×3 최대 풀링을 동시에 수행하고 그 결과(특성 맵)를 채널 방향으로 결합함.
- **1×1 합성곱의 역할 (Bottleneck):**
 - 3×3 이나 5×5 합성곱을 수행하기 전 채널 수를 줄여주는 **차원 축소 (Dimension Reduction)** 효과를 줌.
 - 연산량을 획기적으로 줄이면서도 비선형성을 추가하여 더 풍부한 특징 학습을 가능하게 함.

3. 주요 구조적 특징

- **Global Average Pooling (GAP):** 마지막 단계에서 완전연결층(FC) 대신 각 채널의 평균값을 구하여 하나의 값으로 변환하는 GAP를 도입함. 이를 통해 파라미터 수를 대폭 줄이고 과적합을 방지함.
- **보조 분류기 (Auxiliary Classifier):** 너무 깊은 네트워크에서 학습 시 기울기 소실 문제가 발생할 수 있으므로, 중간 단계에 분류기를 추가하여 학습을 도움. (추론 시에는 사용 안 함)