

10. 비전 트랜스포머

[통계](#) [수정](#) [삭제](#)

goblurry · 방금 전

❤️ 0

트랜스포머



'파이토치 트랜스포머를 활용한 자연어처리와 컴퓨터비전 심층학습' 10장을 바탕으로 학습한 내용을 정리한 포스트입니다.

1. ViT (Vision Transformer)
2. Swin Transformer
3. CvT(Convolutional Vision Transformer)

이전의 '딥러닝 파이토치 교과서' 교재에서, 합성곱 신경망을 이용하여 이미지 데이터를 분류·분할·인식하는 방법을 배웠다. 이 포스트에서는 CNN 모델의 합성곱 계층 방법이 아니라, 트랜스포머 모델에서 사용하는 **셀프 어텐션**을 적용해 이미지를 분류하는 **비전 트랜스포머**를 소개한다.

- 합성곱 모델: '지역 특징'을 추출하여 이미지를 분류
- ViT: 셀프 어텐션 사용하여 전체 이미지를 한 번에 처리

ViT 모델의 한계: 이미지 패치가 좌>우, 상>하 방향으로 순차적으로 입력되어 2차원 구조의 이미지 특성을 온전히 반영하지 못함. (자세한 내용은 이후 설명)

ViT의 파생 모델

- Swin Transformer: '로컬 윈도우'를 사용해, 각 계층의 어텐션이 되는 패치의 크기와 개수를 다양하게 구성해 이미지의 특징을 학습시킴. 기존의 셀프 어텐션을 '로컬 윈도우 간' 어텐션으로 수행하여

계층적으로 이미지 특징을 학습시키고, 어텐션 함수에 상대적 위치 편향을 반영하여 어텐션 값 자체에 위치적 정보를 포함시킴.

- CvT(Convolutional Vision Transformer): ViT에 기존 합성곱 연산 과정을 적용한 모델. 저수준 특징과 고수준 특징을 계층적으로 반영할 수 있음.

ViT 계열의 모델들은 이미지 분류 작업에 매우 효과적이며, 다른 CV 작업에도 광범위하게 적용할 수 있다.

1. ViT

- An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale (Google, 2020) 에서 첫 소개된 이미지 인식을 위한 딥러닝 모델
- 이미지를 '자연어' 처리 방식처럼 분류해 보려는 시도에 의해 탄생

NLP 분야에서 트랜스포머 모델이 큰 성능 향상을 이뤄내며, CV 분야에도 영향을 주게 되었다. ViT의 등장 전까지는 기존의 합성곱 신경망에 트랜스포머 모델의 self attention 모듈을 적용하는 방식이었으나, ViT 모델은 **트랜스포머 구조 자체**를 CV 분야에 적용한 첫 번째 연구이다.

Transformer - BERT

[https://hcnoh.github.io/assets/img/2023-03-07-nlp-04/bert.png!\[\]](https://hcnoh.github.io/assets/img/2023-03-07-nlp-04/bert.png![]) (<https://velog.velcdn.com/images/hyunsun/post/80b8a252-4055-4627-9fd6-cfc635b80679/image.png>)

BERT(Bidirection Encoder Representations from Transformers): 구글에서 2018년에 발표한 거대 언어 모델로, 자연어처리에 널리 사용됨

- 트랜스포머 기반의 인코더 구조를 지닌 언어 모델

BERT와 ViT 비교




그림 10.2 BERT의 ViT 모델 구조 차이

위 이미지는 BERT와 ViT 모델의 구조 차이를 보여준다. BERT의 경우, 문장보다 작은 단위의 토큰들이 순차적으로 입력된다. ViT 모델은 이미지가 격자로 작은 단위의 **이미지 패치**로 나뉘어 순차적으로 입력된다. 상>하, 좌>우로 표현되므로 ViT 모델에 입력되는 이미지 패치는 시퀀셜 배열을 가정한다.

합성곱 모델과 ViT 비교

이미지에서 원하는 특징을 학습하는 과정에서 합성곱 모델과 ViT는 차이가 있다.

합성곱 모델의 경우, 해당 부분만 선택해 학습을 수행한다.

이와 달리 ViT 모델은 이미지를 작은 패치들로 나누어 **각 패치 간 상관관계**를 학습한다. 이를 위해 **셀프 어텐션** 방법을 사용해, 모든 이미지 패치가 서로에게 주는 영향을 고려해 이미지의 전체 특징을 추출하는 것이다.




그림 10.3 합성곱 신경망과 ViT 계층의 차이

입력된 고양이 사진에서 '오른쪽 눈'이라는 특징을 추출하려고 할 때, CNN은 1, 2, 4, 5만 선택해 학습하고 나머지 이미지 패치는 학습에 관여하지 않게 된다. 반면 ViT 모델은 모든 이미지 패치가 학습에 관여한다.

CNN은 좁은 수용 영역(Receptive Field)을 가지므로 전체 이미지 정보를 표현하려면 수많은 계층이 필요하다. 이에 반해 **트랜스포머 모델은 어텐션 거리를 계산하여, 오직 1개의 ViT 계층만으로 전체 이미지 정보를 쉽게 표현할 수 있다.** 또, 패치 단위로 이미지를 처리하기 때문에 더 작은 모델로도 높은 성능을 얻을 수 있다.(CNN: 픽셀 단위)

ViT 모델은 입력 이미지의 크기가 고정되어 있기 때문에 크기가 다른 이미지를 처리하기 위해서는 크기에 대한 전처리가 필요하다. 또한, 패치 간의 상대적인 위치 정보만 고려하기 때문에 이미지 변환에 취약할 수 있다.(CNN은 이미지의 공간 위치 정보를 고려함)

ViT 모델

- Patch Embedding 패치 임베딩: 입력 이미지를 일정한 크기의 패치로 나눈 뒤, 각 패치를 벡터 형태로 변환
- Encoder 인코더: 각 패치와의 관계 학습

이 계층을 통해 이미지의 특징을 추출하고, 분류/회귀 등 작업에 맞는 출력값으로 변환해 사용한다.




그림 10.4 ViT 모델 구조

패치 임베딩

입력 이미지를 작은 패치로 분할하는 과정

- 1. 이미지 크기를 맞추는 전처리 수행
- 2. 전체 이미지를 패치 크기로 분할해 시퀀셜 배열 생성 (이때 CNN 계층 활용)




그림 10.5 이미지 패치 생성 과정

이미지 패치를 생성하는 과정은 위와 같다.

패치 임베딩을 위해 설정해야 하는 하이퍼 파라미터로는 커널 크기와 간격이 있다.

- 커널: 패치의 크기
- 간격: 패치가 이동하는 폭 (스트라이드)

CNN에서 배운 필터의 개념과 비슷하다.

패치 1개의 크기 = (이미지 크기 - 커널 크기) / 스트라이드

3. 이미지 패치 배열에 분류 토큰 추가

이렇게 분할된 이미지 패치들을 배열 형태로 나열할 때 좌>우, 상>하 순서로 배열한다고 설명했다. 이때 가장 왼쪽에 분류 토큰(Special Classification Token [CLS])을 추가한다. 이는 전체 이미지를 대표하는 벡터로, 다양한 이미지 분류 및 검색 문제 해결에 활용된다.

4. 위치 임베딩

위치 임베딩을 사용해 **인접 패치 간 관계**를 학습한다. 패치의 위치 정보를 임베딩 벡터로 변환하고, 기존 이미지 패치 벡터들과 더한다.

5. 계층 정규화 적용 → 패치 임베딩 완성

이렇게 입력 이미지를 작은 패치로 나누어 처리하면, GPU 메모리의 한계를 극복하고 더 큰 이미지에 대한 처리가 가능하다.

인코더

벡터로 변환된 각 패치들은 인코더 계층에 입력값으로 전달 되어 다양한 쿼리, 키, 값 임베딩의 관계를 학습한다. (일반 트랜스포머 모델에서의 작업과 동일)

N개의 인코더 레이어를 반복적으로 적용한 후, 마지막 레이어에서 **분류 토큰(CLS)**의 특징 벡터를 추출한다. 이 분류 토큰 벡터는 앞서 설명했듯, 이미지 데이터를 가장 잘 표현한 특징 벡터이다.

이진 분류 문제: 예를 들어, 고양이인지 아닌지 여부를 구분하는 모델을 학습할 때, ViT 모델은 시퀀셜 산출물(마지막 ViT 인코더 계층에서 산출되는 이미지 패치들의 특징 벡터)을 모두 사용하지 않고, 분류 토큰 벡터만 사용해 문제를 해결한다. (이 벡터를 순방향 신경망 혹은 FC층에 연결하면 됨)

2. Swin Transformer

기존 트랜스포머를 기반으로 하는 모델들의 문제점:

- 패치 크기가 고정되어 세밀한 예측을 필요로 하는 의미론적 분할 등의 작업에 적합하지 않음
- 트랜스포머의 셀프 어텐션은 입력 이미지 크기에 대한 Quadratic(2차) 계산 복잡도를 가져 고해상도 이미지 처리가 어려움
=> 스윈 트랜스포머 등장

스윈 트랜스포머: 계층적 특징 맵을 구성해 Linear(1차) 계산 복잡도를 가짐

- 이미지 분류, 객체 탐지, 영상 분할 등 인식 작업에서 고성능
- 트랜스포머 구조보다 이미지 특성을 더 잘 표현함
- **시프트 윈도** 기술을 사용해 입력 이미지를 일정 크기의 패치로 분할하고, 패치를 쌓아 윈도를 구성함.
구성된 윈도 영역만 셀프 어텐션 계산.
- 기존 트랜스포머 모델과 달리 패치를 겹쳐 더 큰 효율성 제공
- 계층마다 어텐션이 수행되는 패치의 크기와 계수를 계층적으로 적용해 처리하므로 높은 해상도와 다양한 크기를 가진 객체를 효율적으로 처리

ViT와 Swin Transformer의 차이

ViT 모델: 패치 크기가 고정되어 있고, 위치에 대한 제약이 있어서 다양한 이미지 크기와 종횡비를 가진 데이터셋에 적용하기 어려움 + 이미지 공간 정보를 완전히 보존하지 못할 수 있음

이미지의 패치 수 증가 > 학습 데이터 크기 증가 > 모델 학습에 필요한 계산량 증가 >> 대규모 데이터셋에서는 학습에 필요한 컴퓨팅 자원을 많이 사용하게 되는 한계 존재

🌟 **Local Window** : 스윈 트랜스포머에서 입력 이미지를 처리하기 위해 사용하는 고정 크기의 작은 윈도.
이를 활용해 물체의 크기 및 해상도를 **계층적**으로 학습

이 로컬 윈도우를 이동시키는 **시프트 윈도우** 기술을 도입해, 입력 이미지를 일정한 크기의 패치로 분할하고, 특징 맵을 이동시켜 다음 계층에 사용 - 패치 위치를 더 유연하게 다룸

ViT보다 더 높은 정확도, 적은 매개변수 수를 가지면서 더 넓은 범위의 이미지 크기와 종횡비를 다룰 수 있음




그림 10.6 ViT와 스윈 트랜스포머의 네트워크 구조

회색 격자: 패치 / 빨간 격자: 로컬 윈도우

ViT(a)의 네트워크는 계층마다 전체 이미지 내 어텐션이 수행되는 패치 크기 = 개수

스윈 트랜스포머(b)는 로컬 윈도우를 통해 계층마다 어텐션이 되는 패치 크기와 개수를 **계층적으로** 다양하게 적용

표 10.4 ViT와 스윈 트랜스포머 비교

	ViT	스윈 트랜스포머
분류 헤드	[CLS] 토큰 사용	각 토큰의 평균값 사용
로컬 윈도우 사용	X	O
상대적 위치 편향 사용	X	O
계층별 패치 크기	동일함	다양함

스윈 트랜스포머 모델 구조

이미지를 패치 파티션으로 구분한 후,

- 선형 임베딩: 고정 크기로 분할된 패치에 대해 수행하여 각 패치를 고정된 차원의 벡터로 변환
 - 스윈 트랜스포머 블록: 어텐션 계층, 계층 정규화, 다층 퍼셉트론 등 포함하여 패치 간 상호작용 수행
 - 패치 병합: 전체 이미지에 대한 분류 수행
- 이 세 연산이 반복적으로 수행된다.





이전 포스트

6. 합성곱 신경망 (3)

0개의 댓글

댓글을 작성하세요

댓글 작성



Powered by
Stellate