

비전 트랜스포머

ViT(Vision Transformer) :

ViT(Vision Transformer) : 2020년 구글의 논문을 통해 소개된 이미지 인식을 위한 딥러닝 모델. 이미지를 자연어 처리 방식처럼 분류해 보려는 시도에 의해 탄생

CNN모델의 합성곱 계층 방법을 사용하지 않고 트랜스포머 모델에서 사용되는 셀프 어텐션을 적용(이미지 한번에 처리)

문제점) 이미지 패치가 왼->오, 위->아래 방향으로 순차 입력=> 2차원 구조의 특성을 온전히 반영하지 못함
물체의 크기나 해상도를 계층적으로 학습하는 Swin Transformer, Convolutional Vision Transformer 모델 제안

Swin Transformer: 이미지를 작은 윈도우 단위로 나누어 local attention을 수행하고, 윈도우를 이동시키는 방식으로 전역 정보도 반영. 계층적인 구조를 통해 다양한 크기의 특징을 학습.

CvT: Transformer 구조에 합성곱 연산을 도입하여 저수준 특징부터 고수준 특징까지 계층적으로 학습할 수 있도록 하고, attention 계산 과정에서도 일부 연산을 축소하여 효율성을 높임.

ViT(Vision Transformer)는 트랜스포머 구조 자체를 컴퓨터 비전 분야에 적용한 첫번째 연구.




그림 10.2 BERT의 ViT 모델 구조 차이

Bert: 문장보다 작은 단위의 토큰들 순차 입력

ViT 모델: 이미지가 격자로 작은 단위의 이미지 패치로 나누어 순차적으로 입력 (왼->오, 위->아래 방향)




그림 10.3 합성곱 신경망과 ViT 계층의 차이

합성곱 신경망:
특징을 추출하고자 하는 해당 부분만 선택해 학습
-> 좁은 Receptive Field를 가짐-> 전체 이미지 정보를 표현하는데 수많은 계층이 필요

ViT 모델: 이미지를 작은 패치들로 나눠 각 패치간의 상관관계 학습(셀프 어텐션 방법 사용-> 전체 특징 추출)
어텐션 거리를 계산하여 오직 한개의 ViT레이어로 전체 이미지 정보를 쉽게 표현할 수 있음

귀납적 편향(Inductive Bias): 일반화 성능 향상을 위한 모델의 가정을 의미, 일반화 성능에 영향을 줌.

ViT는 강한 구조적 가정을 거의 두지 않고, 입력 이미지를 패치 단위로 나눈 뒤 이를 Query, Key, Value 형태로 변환하여 self-attention을 통해 전체적인 관계를 학습 -> 특정한 공간적 또는 순차적 관계를 강하게 가정하지 않기 때문에 귀납적 편향이 거의 없는 모델로 볼 수 있다.

이러한 특성 때문에 ViT는 다양한 관계를 유연하게 학습할 수 있지만, 충분한 성능을 내기 위해서는 대량의 데이터가 필요. 반대로 CNN처럼 귀납적 편향이 강한 모델은 적은 데이터에서도 효율적으로 학습할 수 있지만, 특정 구조에 제한될 수 있음.

표 10.1 딥러닝 모델의 귀납적 편향

딥러닝 모델	귀납적 편향
합성곱 신경망(CNN)	지역적 편향
순환 신경망(RNN)	순차적 편향
ViT	귀납적 편향이 거의 없음

귀납적 편향은 해당 모델이 가지는 구조와 매개변수들이 데이터에 적합한 가정을 하고 있음을 의미. 올바른 가정은 더 적은 데이터로 높은 일반화 성능. But, 너무 강한 귀납적 편향은 다른 유형의 데이터나 관계를 표현하는데 어려움을 초래

ViT 모델: 패치 임베딩 + 인코더 계층




그림 10.4 ViT 모델 구조

패치 임베딩: 입력 이미지를 작은 패치로 분할하는 과정

이미지 크기를 일정한 크기로 변경 -> 전체 이미지를 패치 크리고 분할해 시퀀셜 배열 생성 -> 합성곱 신경망의 계층 활용




그림 10.5 이미지 패치 생성 과정

패치 임베딩을 위해 커널 크기와 간격 설정 필요

수식 10.1 패치 계산 과정

$$patch\ size = \frac{image\ size - kernel\ size}{stride} = \frac{9 - 3}{3} + 1 = 3$$

Special Classification Token(분류 토큰): 분할된 이미지 배치들을 배열 형태로 나열할 때 가장 왼쪽에 설정하여 전체 이미지를 대표하는 벡터로 특정 문제를 예측하는데 사용.

위치 임베딩(Position Embedding): 인접한 패치 간의 관계 학습. 위치 정보를 임베딩 벡터로 변환하고 기존 이미지 패치 벡터들과 더한다

=> 계층 정규화를 적용해 패치 임베딩 생성. 입력 이미지를 작은 패치로 나눠 처리하면 메모리의 한계를 극복하고 더 큰 이미지를 처리할 수 있음.

ViT(Vision Transformer)의 인코더 계층:

이미지를 일정 크기의 패치로 나눈 뒤 이를 벡터로 변환하여 Transformer 인코더에 입력 -> self-attention을 통해 패치 간 관계를 학습. 여러 인코더 레이어 거쳐-> 전체 이미지를 대표하는 분류 토큰([CLS] 토큰)의 벡터를 추출 -> 완전연결층에 입력해 최종 분류를 수행.

Swin Transformer

2021년 발표한 대규모 비전 인식 모델

기존 트랜스포머 기반으로 하는 모델이 공통적인 문제점: 고정된 패치 크기로 인해 세밀한 예측을 필요로 하는 semantic segmentation같은 작업에 적합하지 않다는 점 -> 계층적 특징 맵을 구성해 1차 계산 복잡도를 갖는 스윈 트랜스포머 등장.

Shifted window를 이용해 입력 이미지를 일정한 크기의 패치로 분할-> 패치를 쌓아 윈도우 구성. 구성된 윈도우 영역만 셀프 어텐션 계산. 기존 트랜스포머와 다르게 패치를 겹쳐 낮은 계산 복잡도 및 더 큰 효율 제공.

표 10.4 ViT와 스윈 트랜스포머 비교

	ViT	스윈 트랜스포머
분류 헤드	[CLS] 토큰 사용	각 토큰의 평균값 사용
로컬 윈도우 사용	X	O
상대적 위치 편향 사용	X	O
계층별 패치 크기	동일함	다양함

특징:

- Local Window Attention(W-MSA): 이미지 패치를 작은 윈도우로 나워서 어텐션 수행; $O(N^2) \rightarrow O(N)$
- Shifted Window(SW-MSA): window를 이동시켜 서로 다른 윈도우 간 정보 연결, 글로벌 정보 학습 가능
- Hierarchical구조: CNN처럼 스테이지 구조 사용, patch merging을 통해: 해상도 감소, 채널 수 증가
- CLS토큰 대신 평균 사용




그림 10.7 스윈 트랜스포머 구조




그림 10.9 스윈 트랜스포머 블록 구조

CvT(Convolutional Vision Transformer)

Transformer 에 CNN구조 결합한 모델: local feature+global feature 동시 학습

ViT는 이미지를 패치 단위로 분할, 이를 트랜스포머모델의 입력으로 사용하는 방식을 사용

CvT는 이미지를 처리하기전에 합성곱 연산을 통해 특징맵을 추출한다. 이를 통해 유의미한 패턴을 추출하고 일정한 크기의 패치로 나눠 트랜스포머 모델의 입력으로 사용한다. 입력되는 패치들은 겹쳐학습




그림 10.14 CvT 모델의 계층적 특징 구조 예시

표 10.4 ViT와 CvT 모델 비교

모델	위치 임베딩	패치 임베딩	어텐션 임베딩	계층형 구조
ViT	O	겹치지 않는 선형 임베딩	선형 임베딩	X
CvT	X	겹치는 합성곱 임베딩 (overlapping)	합성곱 임베딩	O

합성곱 토큰 임베딩: 2D로 재구성된 토큰 맵에서 중첩 합성곱 연산을 수행하는 임베딩 의미. ViT에 계층적인 합성곱 신경망의 성질을 추가하기 위해




그림 10.15 2D 합성곱 기반의 어텐션 임베딩

어텐션에 대한 합성곱 임베딩: 2D로 재구성된 토큰 맵에서 분리 가능한 합성곱 연산을 적용해 성능 저하 및 계산 복잡도를 낮추는 연산