

10장 비전 트랜스포머


ViT (Vision Transformer) : 이미지 분류에서 트랜스포머 모델에서 사용되는 셀프 어텐션 적용

- 스윈 트랜스포머, CvT 모델 제안
- 로컬 윈도우 : 각 계층의 어텐션이 되는 패치의 크기와 개수를 다양하게 구성해 이미지의 특징 학습

CvT : 기존 합성곱 연산 과정을 ViT에 적용한 모델로, 저수준 특징과 고수준 특징을 계층적으로 반영

- Q,K,V 중 키와 값을 기존 특징벡터보다 축소해 계산복잡도 감소

ViT : 트랜스포머 구조 자체를 컴퓨터비전 분야에 적용



BERT : 문장보다 작은 단위의 토큰들이 순차적 입력


ViT : 이미지가 격자로 작은 단위의 이미지 패치로 나뉘어 순차적으로 입력됨 → 시퀀셜 배열 가정

합성곱 VS ViT

합성곱 신경망 : 임베딩은 이미지 패치 중 일부만 선택하여 학습, 이를 통해 이미지 전체 특징 추출

ViT : 임베딩은 이미지를 작은 패치들로 나눠 각 패치 간의 상관관계 학습

⇒ 셀프 어텐션 사용




- attention distance를 계산하여 오직 1개의 ViT 레이어로 전체 이미지 정보를 쉽게 표현

ViT의 귀납적 편향(Inductive Bias) : 일반화 성능향상을 위한 모델의 가정 → 입력 데이터의 다양한 쿼리, 키, 값의 임베딩 형태로 일반화된 관계를 학습하기 때문에 귀납적 편향이 거의 없고, 대용량 데이터에 대해서 이미지 특징들의 관계를 잘 학습하는 모델

ViT 모델

- 패치 임베딩 : 입력 이미지를 트랜스포머 구조에 맞게 일정 크기의 패치로 나누고, 패치를 벡터형태로 변환
- 인코더 : 각 패치와의 관계 학습



패치 임베딩

: 입력 이미지를 작은 패치로 분할하는 과정

- 이미지 크기를 맞추는 전처리가 수행되어야 함
- 이미지 크기 변경 → 시퀀셜 배열 생성




그림 10.5 이미지 패치 생성 과정

수식 10.1 패치 계산 과정

$$patch\ size = \frac{image\ size - kernel\ size}{stride} = \frac{9 - 3}{3} + 1 = 3$$

- 패치 임베딩을 위한 커널 크기, 간격 설정
- 위치 임베딩(Position Embedding) : 인접한 패치 간의 관계 학습 → 패치의 위치 정보를 임베딩 벡터로 변환하고 기존 이미지 패치 벡터들과 더함

인코더 계층 : 각 패치를 벡터로 변환한 후 인코더 계층에 입력으로 전달 → 다양한 쿼리, 키, 값 임베딩의 관계 학습

FASHION MNIST로 실습

- 이미지 프로세서 클래스 : 사전학습된 ViT 모델을 활용해 전처리 진행 → crop, resize 등
- 허깅페이스 라이브러리의 ViT 이미지분류모델 클래스로 사전학습된 모델을 불러올 수 있음
- 학습매개변수클래스 : 모델학습에 필요한 다양한 인자들을 저장하고 관리

표 10.2 학습 매개변수 클래스(TrainingArguments)

매개변수	의미
output_dir	체크포인트 저장 경로
save_strategy	체크포인트 저장 간격 설정 - no: 저장 안 함 - steps: 스텝마다 - epoch: 에폭마다
save_steps	save_strategy= 'steps'일 때 스텝 간격 설정
save_total_limit	체크포인트 최대 저장 개수
evaluation_strategy	체크포인트 평가 간격 설정 - no: 저장 안 함 - steps: 스텝마다 - epoch: 에폭마다

Swin Transformer

: 대규모 비전 인식 모델 → 이전 모델의 공통적인 문제점은 고정된 패치 크기로 인해 세밀한 예측을 필요로 하는 semantic segmentation과 같은 작업에 부적합하다는 문제

⇒ 계층적 특징 맵을 구성해 Linear 계산 복잡도를 갖는 스윈 트랜스포머 등장

- Shifted Window : 입력 이미지를 일정한 크기의 패치로 분할하고 이 패치들을 쌓아 윈도우 구성

⇒ 패치를 겹쳐 큰 효율성, 높은 해상도, 효율적 처리

ViT VS 스윈트랜스포머

ViT : 획일적인 패치크기, 위치 제약, 대규모 데이터셋 학습시 불리

스윈 트랜스포머 : 로컬 윈도우를 이동시키는 시프트 윈도우 기술로 입력 이미지를 일정한 크기의 패치로 분할하고, 특징 맵을 이동시켜 다음 계층에 사용함으로써 패치의 위치를 더 유연하게 다룸






그림 10.6 ViT와 스윈 트랜스포머의 네트워크 구조

- 스윈 트랜스포머의 구조



패치 병합(Patch Merging) : 인접한 패치들의 정보를 저차원으로 축소하는 과정

스윈트랜스포머 블록 : 패치 파티션 이후 반복 적용되며, 선형 임베딩 또는 패치 병합이후에 수행됨




MSA : Multi-head Self-Attention이 아니라 W-MSA, SW_MSA로 구성되며 순차적으로 수행됨

W-MSA : 로컬 윈도우를 사용하는 멀티헤드셀프 어텐션

- 순환 시프트, 역순환 시프트
- 허깅페이스의 사전학습 모델을 통한 실습


CvT : 합성곱 신경망 구조에서 활용하는 계층형 구조를 ViT에 적용한 모델



이미지 처리 전 합성곱 연산을 통해 특징 맵 추출 → 유의미한 패턴을 추출하고 일정한 크기의 패치로 나눠 트랜스포머 모델의 입력으로 사용

- cvt, 계층 정규화, 분류기로 구성
- 분류기 이전 풀링 계층 존재 X

합성곱 토큰 임베딩 : 2D로 재구성된 토큰맵에서 중첩 합성곱 연산을 수행하는 임베딩



- 모델 실습

⇒ 비전 트랜스포머 모델은 분류 문제 해결에 있어 매우 유용한 모델