

12주차

☰ 다중 선택

개념

07. 트랜스포머 (Transformer)

목차

1. 트랜스포머란?
2. 트랜스포머 기반 모델 분류
3. 트랜스포머 구조 상세
 - 입력 임베딩과 위치 인코딩
 - 특수 토큰
 - 인코더
 - 디코더
4. GPT
 - GPT-1
 - GPT-2
 - GPT-3
 - GPT-3.5 (InstructGPT)
 - GPT-4

1. 트랜스포머란?

트랜스포머(Transformer)는 딥러닝 모델 중 하나로, 기계 번역, 챗봇, 음성 인식 등 다양한 자연어 처리 분야에서 많은 성과를 내는 모델이다.

핵심 특징

특징	설명
병렬 처리	기존 순환 신경망(RNN)과 달리 입력 시퀀스를 병렬로 처리

특징	설명
셀프 어텐션	순차 처리나 반복 연결 없이 입력 토큰 간 관계를 직접 모델링
장거리 의존성	임베딩 과정에서 문장 전체 정보를 고려 → 긴 문장도 성능 유지
빠른 학습	기존 순환 신경망보다 학습 속도가 빠르고 병렬 처리 가능

2. 트랜스포머 기반 모델 분류

트랜스포머 기반 모델들은 **오토 인코딩(Auto-Encoding)** 또는 **자기 회귀(Auto-Regressive)** 방식, 또는 두 가지의 조합으로 학습된다.

- A) 양방향 구조 (인코더)
 ← 트랜스포머 모델은 성능이 높고 다양한 구조로 활용된다 →
 → 예측 토큰의 양쪽 토큰들을 모두 참조
- B) 단방향 구조 (디코더)
 → 트랜스포머 모델은 성능이 높고 ...
 → 예측 토큰의 왼쪽 토큰들만 참조

트랜스포머 모델 구조 비교

모델	학습구조	학습방법	학습 방향성
BERT	인코더	오토 인코딩	양방향
GPT	디코더	자기 회귀	단방향
BART	인코더+디코더	오토 인코딩+자기 회귀	양방향+단방향
ELECTRA	인코더+판별기	오토 인코딩+대체 토큰 탐지	양방향
T5	인코더+디코더	오토 인코딩+자기 회귀+다양한 NLP 작업	양방향

3. 트랜스포머 구조 상세

트랜스포머의 인코더와 디코더는 각각 N개의 **트랜스포머 블록(Transformer Block)** 으로 구성된다. 각 블록은 **멀티 헤드 어텐션(Multi-Head Attention)** 과 **순방향 신경망** 으로 이뤄진다.

트랜스포머 전체 구조




그림 7.2 트랜스포머 모델 구조(Q: 쿼리, K: 키, V: 값)

입력 임베딩과 위치 인코딩

트랜스포머는 순환 신경망과 달리 **병렬 구조**로 시퀀스를 처리하기 때문에 **단어의 순서 정보**를 자동으로 제공하지 않는다. 따라서 **위치 인코딩(Positional Encoding)**을 추가로 사용한다.

위치 인코딩 수식

$$PE(pos, 2i) = \sin(pos / 10000^{2i/d_{\text{model}}})$$

$$PE(pos, 2i+1) = \cos(pos / 10000^{2i/d_{\text{model}}})$$

- **pos**: 입력 시퀀스에서 해당 단어의 위치
- **i**: 임베딩 벡터의 차원 인덱스
- 차원 인덱스가 **짝수** → **sin** 함수 적용
- 차원 인덱스가 **홀수** → **cos** 함수 적용

위치 인코딩 시각화 결과:

각 위치(Position)마다 임베딩 차원(Embedding Dimension)에 걸쳐 주기적인 값으로 구성되는 것을 확인할 수 있다.

입력 임베딩 산출 과정

$$\begin{aligned}
 &\text{'트랜스포머' 원-핫 벡터 } [0, 0, \dots, 1, \dots, 0] \\
 &\quad \times \\
 &\quad \text{임베딩 행렬 } [V, d] \\
 &\quad = \\
 &\text{'트랜스포머' 입력 임베딩 } [0.1, 0.9, 0.4, 0.2, 0.1]
 \end{aligned}$$

- N개의 문장이 최대 S개의 토큰 길이를 가질 때 **[N, S, V]** 크기의 원-핫 벡터 텐서는 **[N, S, d]** 크기의 임베딩 텐서로 변환된다.

특수 토큰

트랜스포머는 단어 토큰 이외의 **특수 토큰**을 활용하여 문장을 표현한다.

토큰	의미
<BOS>	문장의 시작 (Beginning of Sentence)
<EOS>	문장의 종료 (End of Sentence)
<UNK>	어휘 사전에 없는 모르는 단어 (Unknown)
<PAD>	모든 문장을 일정한 길이로 맞추기 위한 빈 공간 (Padding)

예시: "ChatGPT는 트랜스포머 모델로 이뤄져 있다"

<BOS> | ChatGPT | 는 | 트랜스포머 | 모델 | 로 | <UNK> | 있다 | <EOS> | <PAD>

인코더

트랜스포머 인코더는 입력 시퀀스를 받아 여러 개의 계층으로 구성된 인코더 계층을 거쳐 연산을 수행한다.

멀티 헤드 어텐션 (Multi-Head Attention)

입력 텐서 차원이 $[N, S, d]$ 라 할 때, 입력 임베딩은 선형 변환을 통해 **3개의 임베딩 벡터**를 생성한다.

벡터	기호	역할
쿼리(Query)	v^q	현재 시점에서 참조하고자 하는 정보의 위치. "질문"이 되는 벡터
키(Key)	v^k	쿼리 벡터와 비교되는 대상. 입력 시퀀스에서 탐색되는 벡터
값(Value)	v^v	어텐션 스코어를 얼마나 반영할지 설정하는 가중치 역할

어텐션 스코어 계산식

$$\text{score}(v^q, v^k) = \text{softmax}\left(\frac{(v^q)^T \cdot v^k}{\sqrt{d}}\right)$$

- $\sqrt{d}$ (벡터 차원의 제곱근)만큼 나눠 **보정** → 벡터 차원이 커질 때 스코어값이 같이 커지는 문제 완화
- 보정된 어텐션 스코어를 **소프트맥스** 함수로 확률적으로 재표현
- 이를 값 벡터와 내적하여 **셀프 어텐션된 벡터** 생성

멀티 헤드 (Multi-Head)

- 셀프 어텐션을 **여러 번** 수행해 여러 개의 헤드를 만든다
- 각 헤드가 독립적으로 어텐션을 수행하고 결과를 합친다
- k개의 셀프 어텐션 벡터는 임베딩 차원 축으로 **병합(concatenation)** 되어 [N, S, d] 형태로 출력

덧셈 & 정규화 (Add & Norm)

- 멀티 헤드 어텐션 통과 전 입력값과 통과 후 출력값을 **더함** → 학습 시 발생하는 기울기 소실 완화
- 임베딩 차원 축으로 정규화하는 **계층 정규화** 적용

순방향 신경망 (Feed-Forward Network)

- 선형 임베딩과 ReLU로 이뤄진 인공 신경망 또는 1차원 합성곱 사용
- 이어서 다시 덧셈 & 정규화 과정 수행

디코더

트랜스포머 디코더는 위치 인코딩이 적용된 **타깃 데이터**의 입력 임베딩을 입력받는다.

마스크 멀티 헤드 어텐션 (Masked Multi-Head Attention)

인코더의 멀티 헤드 어텐션 모듈은 디코더에서 **인과성(Causality)** 을 반영한 **마스크 멀티 헤드 어텐션 모듈**로 대체된다.

- i번째 쿼리 벡터는 **i+1 이상의 키 벡터를 참조할 수 없게** 마스크를 씌운다
- 마스크 영역에 수치적으로 매우 작은 값인 **inf 마스크**를 더함
- 소프트맥스 계산 시 해당 영역의 어텐션 가중치가 0이 됨 → 미래 시점 정보를 무시

디코더의 두 번째 어텐션

- **쿼리 벡터**: 타깃 데이터 (위치 정보 포함한 입력 임베딩 + 위치 인코딩)
- **키, 값 벡터**: 인코더의 소스 데이터 출력
- 인코더와 디코더가 서로 정보를 공유하는 방식

디코더 출력

타깃 데이터를 추론할 때 토큰을 **순차적으로** 생성한다.

추론 순서	디코더 입력	디코더 출력
1	[BOS], [PAD], ...	[BOS], 'ChatGPT', [PAD], ...
2	[BOS], 'ChatGPT', [PAD], ...	[BOS], 'ChatGPT', '는', [PAD], ...
...	...	...
7	[BOS], 'ChatGPT', '는', ..., '있다', [PAD]	..., [EOS], [PAD]

4. GPT

GPT(Generative Pre-trained Transformer) 는 2018년 OpenAI에서 발표한 트랜스포머 기반 언어 모델로 가장 널리 알려진 언어 모델이다.

- 트랜스포머의 **디코더**를 여러 층 쌓아 만든 언어 모델
- 대규모 텍스트 데이터셋으로 사전 학습해 초기화 → 특정 자연어 처리 작업에 맞게 미세 조정
- 자연어 생성, 기계 번역, 질의응답, 요약 등에 활용

GPT-1

GPT-1은 트랜스포머 구조를 바탕으로 한 **단방향(Unidirectional)** 언어 모델이다.

구조적 특징

- 트랜스포머의 **디코더 부분만** 사용 (인코더-디코더 간 어텐션 연산 제외)
- 12개의 헤드를 가진 트랜스포머 디코더를 **12층** 쌓아 구성
- 약 **1억 2천만** 개의 매개변수

사전 학습

- 약 4.5GB의 **BookCorpus** 데이터세트(출판되지 않은 여러 장르의 책 7,000여 권)로 사전 학습
- 입력 문장의 일부만 보고 다음 토큰을 예측하도록 학습 → **비지도 학습**
- 별도의 레이블이 필요 없기 때문에 컴퓨팅 자원이 충분하다면 제약 없이 학습 가능

다운스트림 작업

입출력 구조를 바꾸지 않고 언어 모델을 **보조 학습(Auxiliary Learning)** 해 사용한다.

```

분류:      [Start] Text      Extract → Transformer → Linear
명제 추론: [Start] Premise [Delim] Premise Extract → ...
문장 유사도: [Start] Text1 [Delim] Text2 Extract → ...
다중 선택: [Start] Context [Delim] Answer1 Extract → ...
           [Start] Context [Delim] Answer2 Extract → ...
  
```

특수 토큰: **<start>** (시작), **<delim>** (문장 경계), **<extract>** (문장 마지막)

GPT-2

GPT-2는 GPT-1과 거의 동일한 모델 구조로, 규모를 크게 확장한 모델이다.

GPT-1 대비 차이점

항목	GPT-1	GPT-2
입력 길이	최대 512 토큰	최대 1,024 토큰
디코더 계층 수	12층	48층
매개변수	약 1,200만 개	약 15억 개
사전 학습 데이터	BookCorpus (~4.5GB)	웹 스크래핑 약 8백만 문서 (~40GB)

제로-샷 학습 (Zero-shot Learning)

GPT-2는 **별도의 미세 조정 없이** 다운스트림 작업에서도 사용 가능하다.

사전 학습 과정에서 특정 형식의 데이터를 입력해 작동한다.

예: 'GPT는 놀라워요 = GPT is amazing' 과 같은 형식의 문장을 학습시킨 후, '번역 한글 문장 = ' 을 입력하면 번역된 영문이 출력

GPT-3

GPT-3는 GPT-2와 거의 동일한 모델 구조로, 매개변수를 GPT-2보다 약 116배 늘린 모델이다.

구조적 특징

- 96개의 헤드를 가진 **멀티 헤드 어텐션** 사용
- 트랜스포머 디코더 층도 **96개** 사용
- 멀티 헤드 어텐션 과정에서 연산량을 줄이기 위해 **희소 어텐션(Sparse Attention)** 과 일반 어텐션 혼용
- 토큰 임베딩 크기: 1,600 → **12,888**
- 최대 **2,048개** 토큰 입력 가능
- 약 **1,750억** 개의 매개변수

사전 학습 데이터

데이터 소스	규모
웹 크롤링 (Common Crawl)	약 45TB
위키백과	-
서적 등	-

특징

- **퓨-샷 학습(Few-shot Learning)**: 프롬프트 형식으로 작업 수행
- 질의응답, 수학 문제 풀이, 자연어 추론 등에서 이전 기술적 한계를 극복
- **한계**: 매우 느리고 비용이 많이 들며, 편견·혐오 표현 등이 포함될 수 있음

GPT-3.5 (InstructGPT)

GPT-3.5는 GPT-3의 모델 구조를 그대로 따르면서, RLHF를 도입해 자연스러움을 높인 모델이다.

RLHF (Reinforcement Learning from Human Feedback)

RLHF의 학습 방법은 3단계로 구성된다.

1단계: 지도 미세 조정 (SFT)
데이터세트에서 프롬프트를 샘플링
→ 사람이 적절한 답변을 작성
→ 해당 답변으로 GPT-3 모델을 미세조정

2단계: 보상 모델 학습

모델이 생성한 여러 답변을 모음

- 사람이 생성된 답변을 잘 답한 순서로 랭킹 부여
- 부여된 랭킹으로 리워드 모델 (RM) 을 학습

3단계: 강화 학습으로 최적화

새로운 프롬프트를 샘플링

- GPT-3 모델이 답변을 생성
- 리워드 모델이 생성 결과를 평가
- 평가된 리워드 점수로 모델을 최적화

결과

- GPT-3 모델보다 더 자연스러운 문장 생성 가능
- 약 **60억** 개의 가중치로도 뛰어난 성능
- **환각(Hallucination)** 현상: 모델이 부적절하거나 오류가 많은 답변을 제시하는 현상 여전히 존재
- 2022년 10월 **ChatGPT** 서비스 공개 (GPT-3.5 기반)

GPT-4

GPT-4는 텍스트 데이터뿐만 아니라 이미지 데이터도 인식 가능한 멀티모달(Multimodal) 모델이다.

GPT-3.5 대비 차이점

항목	GPT-3.5	GPT-4
최대 입력 토큰	4,096개	32,768개
처리 가능 단어	약 3,000개	약 25,000개
모달리티	텍스트	텍스트 + 이미지
MMLU 벤치마크	약 70%	약 85%
미국 변호사 시험	213점	298점 (상위 10%)
SAT 읽기/쓰기	670점	710점 (상위 7%)

특징

- 모델의 매개변수 수나 학습 데이터 및 방법은 공개되지 않음
- ChatGPT Plus나 마이크로소프트 Bing을 통해 사용 가능
- 한국어 MMLU 벤치마크에서 77%를 기록하며 GPT-3.5의 영어 성능보다 높은 성능

요약 비교

모델	연도	구조	매개변수	핵심 특징
Transformer	2017	인코더+디코더	-	셀프 어텐션 기반 아키텍처
GPT-1	2018	디코더 ×12	1.2억	단방향, 보조 학습
GPT-2	2019	디코더 ×48	15억	제로-샷 학습
GPT-3	2020	디코더 ×96	1,750억	퓨-샷 학습, 희소 어텐션
GPT-3.5	2022	디코더 (GPT-3 구조)	60억	RLHF , ChatGPT
GPT-4	2023	-	비공개	멀티모달 , 32K 토큰