

트랜스포머 (Transformer)

딥러닝 혁신의 핵심 아키텍처 | Attention Is All You Need (2017)

개요

트랜스포머는 2017년 구글 팀이 논문 'Attention Is All You Need'에서 발표한 신경망 아키텍처입니다. 기존 RNN/LSTM이 시퀀스를 순차적으로 처리하던 방식을 버리고, 어텐션(Attention) 메커니즘만으로 입력 전체를 병렬 처리합니다. 자연어 처리(NLP)는 물론 이미지·오디오·단백질 구조 예측까지 현대 AI의 사실상 표준 구조로 자리잡았습니다.

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right) \cdot V$$

Q (Query)· K (Key)· V (Value) 행렬의 내적을 $\sqrt{d_k}$ 로 스케일 후 softmax로 가중치를 구해 V 에 곱합니다.

핵심 구성요소

구성요소	역할 및 설명
Self-Attention	입력의 모든 위치 쌍 간 관련도를 계산. Q·K·V 행렬로 분해하여 가중 합산합니다.
Multi-Head Attention	어텐션을 h개 헤드로 병렬 수행 후 연결. 다양한 의미 관계를 동시에 포착합니다.
Positional Encoding	순서 정보가 없는 어텐션에 위치 정보를 sin/cos 함수로 주입합니다.
Feed-Forward (FFN)	각 위치별 독립적인 2층 MLP. 비선형 변환으로 표현력을 향상시킵니다.
Layer Normalization	각 서브레이어 출력을 정규화하여 학습 안정성을 확보합니다 (Add & Norm).

인코더-디코더 구조

인코더 (Encoder)	디코더 (Decoder)
6개 레이어 스택 - Self-Attention → FFN - 입력 문장의 문맥 표현 생성 - 모든 위치를 동시에 참조	6개 레이어 스택 - Masked SA → Cross-Attention → FFN - 자기회귀적으로 출력 시퀀스 생성 - 인코더 출력에 Cross-Attention 적용

RNN 대비 주요 장점

장점	설명
병렬 처리	시퀀스를 순차 처리하지 않아 GPU 활용도가 대폭 향상됩니다.
장거리 의존성	거리에 관계없이 모든 위치 쌍 간 직접 어텐션이 가능합니다.
확장성 (Scaling)	모델 크기를 늘릴수록 성능이 예측 가능하게 향상됩니다 (Scaling Law).
전이 학습	대규모 사전학습 후 소량 데이터로 다양한 태스크에 파인튜닝 가능합니다.

GPT (Generative Pre-trained Transformer)

언어 생성 AI의 패러다임 전환 | OpenAI

GPT란?

GPT는 OpenAI가 개발한 디코더 전용(Decoder-only) 트랜스포머 모델입니다. 대규모 텍스트 코퍼스로 '다음 토큰 예측(Next Token Prediction)'이라는 단일 목표로 사전학습한 뒤, 다양한 언어 태스크에 파인튜닝하거나 프롬프트만으로 활용합니다. GPT-3부터는 파인튜닝 없이 few-shot 학습으로도 뛰어난 성능을 보이며, ChatGPT-GPT-4로 진화하며 대화형 AI의 대중화를 이끌었습니다.

GPT 버전별 발전사

모델	연도	파라미터	핵심 기여
GPT-1	2018	117M	사전학습 + 파인튜닝 패러다임 제시
GPT-2	2019	1.5B	Zero-shot 학습 가능성 확인, 공개 논란
GPT-3	2020	175B	Few-shot 학습으로 다양한 태스크 수행, API 공개
InstructGPT	2022	~1.3B+	RLHF로 인간 의도 정렬, ChatGPT의 기반
GPT-4	2023	비공개	멀티모달(텍스트+이미지), 추론 능력 대폭 향상

GPT 학습 파이프라인

1단계 사전학습	수천억 토큰 인터넷 텍스트로 다음 단어 예측 학습. 자기지도학습(Self-supervised)으로 레이블이 불필요합니다.
2단계 지도 파인튜닝	고품질 인간 작성 예시 데이터로 지도학습. 특정 태스크 또는 대화 형식에 적응합니다.
3단계 RLHF	Reward Model 훈련 후 PPO 알고리즘으로 강화학습. 인간 선호도에 맞춰 출력 품질을 정렬(Alignment)합니다.

트랜스포머 vs GPT 비교

항목	트랜스포머 (원본)	GPT
구조	인코더 + 디코더	디코더 전용
어텐션	양방향 (인코더)	단방향 (Masked)
학습 목표	번역 등 지도학습	다음 토큰 예측
활용	번역·요약 등	텍스트 생성·대화
대표 모델	T5, BART	GPT-3/4, ChatGPT

GPT가 불러온 변화

키워드	설명
창발적 능력 (Emergent)	모델 규모가 커지면서 예상치 못한 수학적 추론·코드 작성 능력이 나타납니다.

키워드	설명
대화형 AI 대중화	ChatGPT는 출시 5일 만에 100만 사용자를 돌파해 AI 진입장벽을 낮췄습니다.
프롬프트 엔지니어링	파인튜닝 없이 프롬프트 설계만으로 모델 행동을 제어하는 새 패러다임이 등장했습니다.
Alignment 문제 부상	모델 정렬(안전성·윤리)이 AI 연구의 핵심 과제로 떠오르며 RLHF가 표준화되었습니다.