


자연어처리와 파이토치 트랜스포머 7장

BERT

: 구글에서 발표한 언어모델, 트랜스포머 기반 양방향 인코더를 사용하는 자연어처리 모델


- 양방향 인코더 : 입력 시퀀스를 양쪽 방향에서 처리하여 이전과 이후의 단어를 모두 참조하며 단어의 의미와 문맥을 파악
- 대규모 데이터를 사용해 사전학습됨 → 전이학습에 주로 활용



사전학습 방법


- Masked Language Modeling (MLM) : 입력 문장에서 임의로 일부 단어를 마스킹하고 해당 단어를 예측
 - 양방향 문장 학습 : 입력 문장에서 누락된 단어를 추론하는 능력
- NSP (Next sentence prediction) : 두 개의 문장이 주어졌을 때, 두번째 문장이 첫번째 문장의 다음에 오는 문장인지 여부를 판단하는 작업

- CLS : 입력 문장의 시작 부분에 추가되는 토큰
- SEP : 입력 문장 내에서 두 개 이상의 문장을 구분하기 위해 사용되는 토큰




BART

- 메타의 FAIR 연구소에서 발표한 트랜스포머 기반의 모델
- BERT 인코더와 GPT 디코더를 결합한 시퀀스-시퀀스 구조로 노이즈 제거 오토인코더로 사전 학습
- BART : 사전학습 시 노이즈 제거 오토인코더 사용 : 문장에 임의로 노이즈를 추가하고 원래 문장을 복원하도록 학습
- BART는 인코더와 디코더 모두 사용



- MLM 외에도 다양한 노이즈기법 사용
 - 토큰 마스킹 : MLM과 동일한 기법
 - 토큰 삭제 : 입력 문장의 일부 토큰을 치환하는 게 아니라 삭제하는 방법
 - 문장 순열 : 마침표를 기준으로 문장을 나누고 문장의 순서를 섞는 방법
 - 문서 회전 : 임의의 토큰으로 문서가 시작하도록 함
 - 텍스트 채우기 : 몇 개의 토큰을 하나의 구간으로 묶고 일부 구간을 마스크 토큰으로 대체
- 미세조정방법



- 추상적 질의응답, 문장요약에 적합

BART 모델 학습 및 평가

- 루지(ROUGE) 점수 : 생성된 요약문과 정답 요약문이 얼마나 유사한지 평가
 - ROUGE-L, ROUGE-LSUM, ROUGE-W
- 평가 라이브러리 : 루지 라이브러리, Abseil 파이썬 공통 라이브러리

ELECTRA

- ELECTRA : 2020년 구글에서 발표한 트랜스포머 기반의 모델
- 생성자, 판별자 사용
- 사전학습방법
 - RTD : 판별 모델은 각 입력 토큰이 원본 문장의 토큰인지 생성자 모델로 인해 바뀐 토큰인지 학습




그림 7.20 ELECTRA 모델 학습 방법

T5

- Text to Text Transfer Transformer : 자연어 처리 분야의 딥러닝 모델
- 텍스트-텍스트 구조
- 문장 번역, 요약, 질의응답, 텍스트 분류 등
- 생성(generate) : 입력 문장에 대한 요약문 생성
- 빔 개수 : 빔 서치 알고리즘의 빔 크기
- 반복 페널티 : 중복 토큰 생성을 제어하는 값
- 길이 페널티 : 생성된 시퀀스 길이에 대한 보상 제어