




자연어 처리와 컴퓨터비전 심층학습 7장: BERT~

⚙ Status	Not started
👤 Assignee	 시현 이
📌 Task type	개념및코드필사
≡ Description	자연어 처리와 컴퓨터비전 심층학습 7장: BERT~

BERT(Bidirectional Encoder Representations from Transformers)

:트랜스포머 기반 양방향 인코더를 사용하는 자연어 처리 모델

- 양방향 인코더: 입력 시퀀스를 양쪽 방향에서 처리해 이전과 이후의 단어를 모두 참조하면서 단어의 의미와 문맥을 파악
 - 기존의 언어 모델 → (좌 → 우) 이전단어만 고려
- 이전과 이후 단어 모두 참조
- 대규모 데이터를 사용해 사전 학습돼 있으므로 전이 학습에 주로 사용됨
- 일부 또는 전체를 다른 작업에서 재사용
- 트랜스포머의 인코더 모듈만을 사용해 입력 문장을 처리
 - 인코더: 입력 문장의 단어들을 임베딩해 각 단어의 의미를 벡터화한 후, 이를 순차적으로 처리해 문장 전체의 의미를 추출
- 사전 학습을 위해 마스킹 된 언어 모델링(MLM)과 다음 문장 예측 방법(NSP) 사용



사전 학습 방법

마스킹된 언어 모델링(Masked Language Modeling, MLM)

: 입력 문장에서 임의로 일부 단어를 마스킹하고 해당 단어를 예측하는 방식


- 'I'm learning PyTorch' → learning을 마스킹 → 'I'm [MASK] pyTorch'가 되어 BERT는 [MASK]에 들어갈 단어를 예측

다음 문장 예측(Next Sentenc Prediction, NSP)

: 두 개의 문장이 주어졌을 때, 두번째 문장이 첫번째 문장의 다음에 오는 문장인지 여부를 판단하는 작업

- 두 문장이 연속적인 관계인지 아닌지 예측 → BERT는 두 문장 간의 관계를 학습, 의미적 유사성 파악
- BERT 모델은 입력 문장에 특수한 토큰들을 추가해 모델이 학습하고 추론하는 과정에서 필요한 정보를 제공
 - [CLS], [SEP],[MASK] 토큰이 사용됨

- [CLS]
 - 입력 문장의 시작 부분에 추가되는 토큰
 - 문장 분류 작업을 위한 정보 제공(어떤 유형의 문장인지 파악)
- [SEP]
 - 입력 문장 내에서 두 개의 이상의 문장을 구분하기 위해 사용되는 토큰
 - 입력 문장들을 구분해 각 문장을 독립적인 문장으로 인식
- [MASK]
 - 입력 문장 내에서 임의로 선택된 단어를 가리키는 특별한 토큰
 - 주어진 문장에서 일부 단어를 가린 후 모델의 학습과 예측에 활용
- [CLS] 문장-1 [SEP] 문장-2 [MASK][SEP] 등의 구조를 가질 수 있음



- [MASK] 토큰 적용 방법
 - 텍스트 토큰 중 15%에 해당하는 단어를 대상으로 마스킹을 수행(100개의 토큰 중에 15개 단어 마스킹)
 - 이 중 80%는 [MASK] 토큰으로 대체하고 10%는 어휘 사전에 존재하는 무작위 단어로 변경. 나머지 10%는 실제 토큰을 그대로 사용

- 분류 문제에서 일반적으로 [CLS] 토큰 벡터를 사용, 각 토큰마다 예측이 필요한 경우에는 모든 토큰 벡터를 사용

BART

:BART(Bidirectional Auto-Regressive Transformer)는 메타의 FAIR 연구소에서 발표한 트랜스포머 기반의 모델

- BERT의 인코더와 GPT의 디코더를 결합한 시퀀스-시퀀스(Seq2Seq)구조로 노이즈 제거 오토인코더(**Denoising Autoencoder**)로 사전 학습됨
 - 오토인코더 사전 학습 바업은 입력 데이터에 잡음을 추가, 잡음이 없는 원본 데이터를 복원하도록 학습하는 방식으로 수행됨
- 사전 학습 시 BERT의 인코더와 GPT의 디코더가 학습하는 방법을 일반화해 학습





그림 7.15 BART 사전 학습 시각화

- 노이즈가 추가된 텍스트를 인코더에 입력하고 원본 텍스트를 디코더에 입력해 디코더가 원본 텍스트를 생성할 수 있게 학습하는 방식
- 문장 구조의 의미를 보존하면서 다양함 변형을 학습할 수 있음
 - 입력 문장에 큰 제약 없이 노이즈 기법을 적용할 수 있으므로 더 풍부한 언어적 지식을 습득할 수 있게 함

- BERT는 인코더만 사용 ↔ BART는 인코더와 디코더를 모두 사용



- 인코더의 마지막 계층과 디코더의 각 계층 사이에만 어텐션 연산을 수행
- BART의 인코더에서는 입력 문장의 각 단어를 임베딩하고 여러 층의 인코더를 거쳐 마지막 계층에서는 입력 문장 전체의 의미를 가장 잘 반영하는 벡터가 생성됨
 - 생성된 벡터는 디코더가 출력 문장을 생성할 때 참고됨
 - 디코더의 각 계층에서는 이 벡터와 이전 계층에서 생성된 출력 문장의 정보를 활용해 출력 문장을 생성
 - 정보 전달을 최적화하고 메모리 사용량을 줄일 수 있음

사전 학습 방법

: 토큰 마스킹, 토큰 삭제, 문장 교환, 문서 회전, 텍스트 채우기 기법이 사용됨



- 토큰 마스크
 - MLM과 동일한 기법, 입력 문장의 일부 토큰을 마스크 토큰으로 치환하는 방법
 - 문장 내에서 어떤 단어가 중요한 역할을 하는지 학습할 수 있으며, 입력 문장의 문맥을 이해하고 문장 내에서 중요한 정보를 추출하는 능력이 향상됨
- 토큰 삭제
 - 입력 문장의 일부 토큰을 치환X, 삭제하는 방법
 - 어떤 위치의 토큰이 삭제되었는지도 맞춰야함
 - 입력 문장에서 불필요한 정보보다 중요하지 않은 정보를 자동으로 필터링해 처리할 수 있음
 - 모델의 학습과 예측 시간을 줄이고, 모델의 일반화 성능을 향상시킴
- 문장 순열
 - 마침표를 기준으로 문장을 나눈 뒤, 문장의 순서를 섞는 방법
 - 원래의 문장 순서를 맞춰야함
 - 문장 내에서 단어들이 어떻게 연결돼 있는지 더 잘 파악
- 문서 회전
 - 임의의 토큰으로 문서가 시작하도록 함

- 문장의 순서는 유지
- 문서의 원래의 시작 토큰을 맞춰야하면 모델이 문서의 시작점을 인식할 수 있도록 함
- 텍스트 채우기
 - 몇 개의 토큰을 하나의 구간으로 묶고 일부 구간을 마스크 토큰으로 대체
 - 묶은 구간의 길이는 0부터 임의의 값까지 설정, 일반적으로 포아송 분포로 구간을 나누며, 푸아송 분포의 파아미터 값을 3으로 설정
 - 구간의 길이가 0인 경우는 해당 위치에 변환된 토큰이 없음을 의미

미세 조정 방법

:BART는 미세 조정 시 각 다운스트림 작업에 맞게 입력 문장을 구성(인코더와 디코더에 다른 문장 구조로 입력)




그림 7.18 BART 미세 조정 구조

- 문장 분류 작업에서는 입력 문장을 인코더와 디코더에 동일하게 입력하고 디코더의 마지막 토큰 은닉 상태를 선형 분류기의 입력값으로 사용
 - BERT의 CLS 토큰과 비슷하지만, BART는 전체 입력과 어텐션 연산이 적용된 은닉 상태를 사용
- 토큰 분류 작업에서도 BART는 입력 문장을 인코더와 디코더에 동일하게 입력
 - 디코더의 각 시점별 마지막 은닉 상태를 토큰 분류기의 입력값으로 사용

- 전체 입력과 디코더의 각 시점별 은닉 상태와의 어텐션 연산을 수행
- 문장 생성 작업 수행 가능
 - 입력값을 조작해 출력을 생성하는 **추상적 질의응답(Abstactive Question Answering)**과 **문장 요약(Summarization)**과 같은 작업에 적합
- ex) 기계 번역 작업에서 BART는 사전 학습된 인코더에 기계 번역을 위한 인코더를 추가해 작업 수행
 - 추가된 인코더는 기존의 단어 사전을 사용하지 않아도 되며, 디코더는 사전 학습된 가중치와 단어 사전을 사용
 - 학습 단계
 1. 새로 추가된 트랜스포머 인코더의 가중치와 위치 임베딩, 그리고 첫번째 인코더 층의 셀프 어텐션 입력 행렬 가중치만 학습
 2. 모든 신경망의 가중치를 작은 반복으로 학습

ELECTRA

: Efficiently Learning an Encoder that Classifies Token Replacements Accurately)

- 입력을 마스킹하는 대신 생성자(Generator)와 판별자(Discriminator)를 사용해 사전 학습을 수행
- 사전학습 접근 방식-변화기 모델인 생성자와 판별자를 학습하므로 생성적 적대 신경망(GAN)과 유사한 방법으로 학습이 수행
- 생성 모델은 실제 데이터와 비슷하게 토큰을 생성해 다른 토큰으로 대체.
- 판별 모델이 생성 모델이 만든 데이터와 실제 데이터를 입력받아 어떤 데이터가 실제 데이터인지, 아니면 생성된 데이터인지 구분
- 대규모 데이터셋에서 모델을 더 빠르게 학습 가능
- BERT와 비교하면 모델의 매개변수가 더 작음

사전 학습 방법

- 생성자 모델과 판별자 모델은 모두 트랜스포머 인코더 구조를 따름

- 생성자 모델: 입력 문장의 일부 토큰을 마스크 처리하고 마스크 처리된 토큰이 원래 어떤 토큰이었는데지 예측하며 학습
 - 15%의 마스크 처리
- 판별자 모델: 각 입력 토큰이 원본 문장의 토큰인지 생성자 모델로 인해 바뀐 토큰인지 맞히며 학습 ⇒ RTD(Replaced Token Detection)





그림 7.20 ELECTRA 모델 학습 방법

- GAN과의 차이점
 1. 생성자 모델이 원래 토큰을 정확히 예측한 경우 이 토큰은 생성된 토큰이 아닌 원본 토큰으로 인식
 2. 생성모델이 마스킹된 언어 모델을 통해 학습되며, 판별모델을 각 토큰이 바뀐 토큰인지 아니면 원본 토큰인지를 구분하도록 학습
 3. 일부 토큰이 마스크 처리된 텍스트를 입력으로 받음
- 생성 모델과 판별 모델은 모두 트랜스포머 인코더 구조를 따름 → 두 모델이 같은 개수의 계층으로 구성돼 있다면 가중치를 공유할 수 있어 더 빠르게 학습할 수 있음
 - but, 가중치 완전 공유 → 생성 모델의 성능이 너무 높아져 판별 모델이 학습할 수 없게 됨
 - 따라서 생성모델을 판별 모델의 1/2~1/4 크기로 바꿔 설정하고 모든 가중치를 공유하는 대신 임베딩 계층의 가중치만 공유
- 사전 학습이 완료되면 생성 모델을 사용하지 않고 오직 판별 모델만 사용해 다운스트림 작업을 수행(미세조정)

T5

: Text-to-Text Transfer Transformer

- 인코더-디코더 모델 구조를 기반. GLUE, SuperGLUE, CNN/DM(Cable News Network/Dail Mail) 등의 데이터셋에서 SOTA(State-of-the-art) 달성
- Text-to-Text 구조: 입출력을 코드 토큰 시퀀스로 처리



- CoLA 데이터셋을 사용하면 문법적으로 허용 가능한 문장과 그렇지 않은 문장 구분 가능
- STS-B(The Semantic Textual Similarity Benchmark)을 사용하면 문장 간 의미적 유사성 측정할 수 있음
- T5는 C4 데이터셋을 활용해 다양한 자연어 처리 작업을 수행할 수 있게 사전 학습
 - 사전 학습 방식은 비지도 학습 방식으로 입력 문장의 일부 구간을 마스킹해 입력 시퀀스를 처리하며, 출력 시퀀스는 실제 마스킹된 토큰과 마스크 토큰의 연결로 구성됨
 - 이때마다 문장마다 유일한 마스크 토큰을 의미하는 센티널 토큰(Sentinel Token)이 사용됨
- 마스킹 토큰을 예측하는 것을 목적으로 사전 학습
- T5의 미세조정은 지도 학습 방식으로 학습